Abschlussprüfung Sommer 2027

Fachinformatiker für Daten- und Prozessanalyse

Dokumentation der betrieblichen Projektarbeit

Datenbasierte Analyse der Durchlaufzeiten im Wareneingang eines Logistikzentrums und Ableitung von Verbesserungsvorschlägen

Analyse vorhandener Prozessdaten, Ermittlung von Verzögerungen und Entwicklung von Vorschlägen zur Verbesserung des Wareneingangsprozesses

Prüfling:
Vladimir Larionov
Prüflingsnummer: XYZ

Ausbildungsbetrieb:
MainLogistik GmbH
Demostrasse 2, 90402 Nürnberg

Zuständige Kammer:
IHK Nürnberg für Mittelfranken

Fachrichtung: Daten- und Prozessanalyse **Prüfungsjahr:** 2027
Abgabedatum: 14.05.2027

Inhaltsverzeichnis

1 Einleitung 2
1.1 Projektumfeld und Schnittstellen 2
1.2 Zielgruppe und Rahmenbedingungen 2
1.3 Zielsetzung und Motivation 3
2 Problemstellung und Analyse 3
2.1 Ausgangssituation (Ist-Zustand) 3
2.2 Soll-Konzept 3
2.3 Stakeholder-Analyse 4
2.4 Wirtschaftlichkeitsbetrachtung (Kosten, Nutzen, Amortisation) 5
2.5 Schutzbedarfsanalyse (Datenschutz und Datensicherheit) 6
3 Projektplanung 7
3.1 Projektziele (fachlich, organisatorisch, zeitlich) 7
3.2 Vorgehensmodell (Wasserfallmodell) 7
3.3 Ablauf- und Zeitplanung 8
3.4 Ressourcen-, Meilenstein- und Risikoplanung 9
4 Entwurf 10
4.1 Datenmodell und Datenquellen 10
4.2 Analysemethoden und technische Entscheidungen 11
4.3 Schnittstellen und Datenflüsse 12
5 Projektdurchführung 13
5.1 Datenaufbereitung 13
5.2 Datenanalyse 14
5.3 Auswertung und Visualisierung 15
5.4 Verbesserungsvorschläge 16
5.5 Soll-Ist-Abgleich während der Umsetzung 17
6 Qualitätssicherung und Abnahme 18
6.1 Testkonzept 18
6.2 Testergebnisse (Testmatrix) 18
6.3 Übergabe und Abnahme 19
7 Projektergebnisse 19
7.1 Darstellung des Endergebnisses 19
7.2 Abgleich mit den Projektzielen 20
7.3 Bewertung des Nutzens für den Betrieb 20
8 Fazit und Ausblick 21
8.1 Zusammenfassung 21

8.2 Soll-Ist-Vergleich (Zeit, Kosten, Ziele) 21
8.3 Reflexion und Ausblick 21
9 Verwendete KI-Hilfsmittel 22
10 Quellenverzeichnis 22
11 Glossar 22
12 Abkürzungsverzeichnis 23
13 Anlagen 24
13.1 Anlage 1: Detaillierte Zeitplanung 24
14 Kundendokumentation 1
14.1 Einführung (Zweck und Zielgruppe) 1
14.2 Bedienungsanleitung / Hinweise zur Auswertung 1
14.3 Technische Hinweise (Systemvoraussetzungen, Installation) 2
14.4 Anhang (Kurzanleitung, FAQ) 3

Abbildungsverzeichnis

Abbildung 1: Gantt-Diagramm der Projektphasen....9
Abbildung 2: Datenfluss des Projekts....12
Abbildung 3: Verteilung der Gesamtdurchlaufzeit (links) und Anteil der Schritte an der Gesamtzeit (rechts)....15
Abbildung 4: Gesamtdurchlaufzeit nach Warenart (links) und Zusammenhang mit der Anzahl der Paletten (rechts)....16

Tabellenverzeichnis

Tabelle 1: Zielgruppenanalyse....2
Tabelle 2: Stakeholder-Analyse....4
Tabelle 3: Projektkosten....5
Tabelle 4: Nutzen und Amortisationsdauer....5
Tabelle 5: Schutzbedarfsanalyse....6
Tabelle 6: Risikoanalyse....6
Tabelle 7: Grobe Zeitplanung....8
Tabelle 8: Ressourcenplanung....9
Tabelle 9: Meilensteine....9
Tabelle 10: Projektrisiken....10
Tabelle 11: Datenfelder der Rohdaten (wareneingang_roh.csv)....11
Tabelle 12: Technische Entscheidungen....11
Tabelle 13: Kennzahlen....11
Tabelle 14: Datenflüsse....13
Tabelle 15: Datenqualitätsprüfung....13
Tabelle 16: Schrittzeiten und Anteil an der Gesamtzeit:....14
Tabelle 17: Median der Gesamtdurchlaufzeit je Gruppe (Minuten)....14
Tabelle 18: Statistische Tests (Spearman und Kruskal-Wallis)....14
Tabelle 19: Regressionsmodell B: Wirkung der Merkmale in Minuten....15
Tabelle 20: Verbesserungsvorschläge mit Kosten-Nutzen....17
Tabelle 21: Soll-Ist-Vergleich der Zeit (Phase 1 bis 6)....17
Tabelle 22: Soll-Ist-Vergleich der Inhalte....18
Tabelle 23: Testmatrix....19
Tabelle 24: Abnahmekriterien....19
Tabelle 25: Abgleich mit den Projektzielen....20
Tabelle 26: Soll-Ist-Vergleich der Zeit (Phase 7 bis 9)....21
Tabelle 27: Soll-Ist-Vergleich der Kosten und des Nutzens....21
Tabelle 28: Verwendete KI-Hilfsmittel....22
Tabelle 29: Glossar....23
Tabelle 30: Abkürzungsverzeichnis....23
Tabelle 31: Detaillierte Zeitplanung....24
Tabelle 32: Ergebnisdateien und ihre Bedeutung....1
Tabelle 33: Benötigte Pakete und getestete Versionen....2
Tabelle 34: FAQ....3

1 Einleitung

1.1 Projektumfeld und Schnittstellen

Die MainLogistik GmbH ist ein fiktives Logistikunternehmen mit Sitz in Nürnberg und rund 170 Mitarbeitenden. Das Unternehmen bietet Lager- und Distributionsdienstleistungen an. Das Projekt wird im Bereich Wareneingang eines Logistikzentrums durchgeführt.
Im Wareneingang werden täglich Waren von verschiedenen Lieferanten angenommen, kontrolliert, erfasst und für die Einlagerung vorbereitet. Der betrachtete Prozess beginnt mit der Ankunft der Ware und endet mit der Vorbereitung für die Einlagerung. Dabei entstehen Prozessdaten, zum Beispiel Zeitstempel und Angaben zu den Lieferungen.
Es handelt sich um ein internes Analyseprojekt. Das Projekt hat folgende Schnittstellen:

Personelle Schnittstellen: Der Projektbearbeiter führt das Projekt durch. Ein fiktiver Ansprechpartner aus dem Fachbereich Wareneingang beantwortet fachliche Fragen zum Prozess und zu den Daten. Ein fiktiver Projektauftraggeber der MainLogistik GmbH nimmt die Ergebnisse ab.

Organisatorische Schnittstellen: Der Wareneingang liefert die Prozessdaten. Der nächste Prozessschritt im Logistikzentrum ist die Einlagerung. Dort werden die Waren auf Lagerplätze gebracht. Verbesserungen im Wareneingang können deshalb auch die Einlagerung betreffen.

Technische Schnittstellen: Es gibt keine Verbindung zu produktiven Systemen. Die synthetischen Prozessdaten werden als Dateien in einer getrennten Arbeitsumgebung bereitgestellt.

1.2 Zielgruppe und Rahmenbedingungen

Die Projektdokumentation und die Ergebnisse dieses Projektes richten sich an Personen, die unterschiedliche Erwartungen an das Projekt und unterschiedliche Vorkenntnisse haben. In Tabelle 1 werden die wichtigsten Zielgruppen beschrieben.

Zielgruppe	Erwartung	Vorkenntnisse	Darstellungsform
Auftraggeber (Leitung Wareneingang)	Klare Ergebnisse, Entscheidungsgrundlage, wirtschaftlicher Nutzen	Prozesswissen – hoch, Datenanalyse – gering	Einfache Diagramme und Kennzahlen; Nutzen in Euro
Fachbereich Wareneingang (Ansprechpartner und Mitarbeitende)	Praktische Vorschläge, Verständnis von Verzögerungsursachen	Prozesswissen – sehr hoch, Datenanalyse – gering	Einfache Sprache; Schritt-für-Schritt-Anleitung; Fachbegriffe erklärt
Prüfungsausschuss der IHK	Nachvollziehbares Vorgehen, eigene Leistung, Methoden, Wirtschaftlichkeit	IT und Datenanalyse – hoch, Betrieb unbekannt	Fachsprache mit Begründungen und Quellenangaben

Tabelle 1: Zielgruppenanalyse

Organisatorische und zeitliche Rahmenbedingungen. Das Projekt wird von einer Person durchgeführt. Der Zeitrahmen beträgt 40 Stunden, davon höchstens 6 Stunden für die Dokumentation. Die Durchführung ist vom 12.04. bis 23.04.2027 geplant. Sie beginnt erst nach der Genehmigung durch den Prüfungsausschuss. Es geht um ein Übungsprojekt mit fiktivem Auftraggeber und fiktivem Ansprechpartner.

Technische Rahmenbedingungen. Die Analyse wird mit Python (Jupyter Notebook, Pandas, Matplotlib, SciPy/Statsmodels) durchgeführt. Excel dient zum Ansehen der Rohdaten, draw.io zur Darstellung des Prozesses. Die Arbeit findet in einer getrennten Arbeitsumgebung statt. Produktive Systeme der MainLogistik GmbH werden nicht verändert.

Daten und Datenschutz. Es werden synthetische, aber realistisch aufgebaute Prozessdaten verwendet. Die Daten enthalten keine personenbezogenen Angaben und keine Betriebsgeheimnisse.

Wirtschaftliche Rahmenbedingungen. Für das Projekt gibt es kein eigenes Budget. Die Werkzeuge sind kostenlos oder schon vorhanden. Kosten entstehen nur durch die Arbeitszeit.

Abgrenzung. Nicht Teil des Projekts sind die Umsetzung der Verbesserungsmaßnahmen, ein neues Lagerverwaltungssystem, größere Änderungen an der IT-Infrastruktur und Änderungen am Aufbau des Lagers.

1.3 Zielsetzung und Motivation

Motivation. Im Wareneingang entstehen täglich Prozessdaten. Diese Daten werden bisher nicht gemeinsam ausgewertet. Deshalb ist nicht bekannt, welche Prozessschritte die Durchlaufzeit verlängern und warum. Lange Durchlaufzeiten können zu Wartezeiten, höheren Kosten und Verzögerungen in den folgenden Prozessen führen. Mit einer Datenanalyse können Verbesserungen auf Fakten statt auf Vermutungen gestützt werden. Außerdem wendet der Projektbearbeiter in diesem Projekt die in der Umschulung erlernten Kenntnisse praktisch an: Datenaufbereitung, statistische Analyse, Visualisierung und Wirtschaftlichkeitsbetrachtung.

Zielsetzung. Ziel des Projekts ist es, die Durchlaufzeiten im Wareneingang der MainLogistik GmbH anhand von Prozessdaten zu untersuchen. Dabei sollen Verzögerungen und ihre Ursachen erkannt werden. Auf dieser Grundlage werden Verbesserungsvorschläge entwickelt und wirtschaftlich bewertet. Der Auftraggeber erhält damit eine Grundlage für Entscheidungen, um die Durchlaufzeiten zu reduzieren und den Wareneingangsprozess effizienter zu gestalten. Die genauen Teilziele (fachlich, organisatorisch, zeitlich) stehen in Kapitel 3.1.

2 Problemstellung und Analyse

2.1 Ausgangssituation (Ist-Zustand)

Im Wareneingang der MainLogistik GmbH kommen an einem Arbeitstag etwa 35 Lieferungen von verschiedenen Lieferanten an (Annahme, siehe Kapitel 2.4). Jede Lieferung durchläuft dieselben Prozessschritte: Ankunft der Ware, Annahme, Kontrolle, Erfassung und Vorbereitung für die Einlagerung. In jedem Schritt entstehen Prozessdaten, zum Beispiel Zeitstempel und Angaben zur Lieferung (Lieferant, Warenart, Wochentag).

Diese Daten werden bisher nicht zusammenhängend ausgewertet. Daraus entstehen folgende Probleme:

- Es ist nicht bekannt, wie sich die gesamte Durchlaufzeit auf die einzelnen Prozessschritte verteilt.
- Prozessschritte mit langen Warte- oder Bearbeitungszeiten sind nur schwer zu erkennen.
- Mögliche Ursachen für Verzögerungen, zum Beispiel bestimmte Lieferanten, Warenarten oder Wochentage, sind nicht untersucht.
- Verbesserungen können nur auf Vermutungen gestützt werden, weil eine ausreichende Datengrundlage fehlt.

Die Folgen sind Wartezeiten, höhere Kosten und Verzögerungen in den folgenden Prozessen, zum Beispiel in der Einlagerung.

2.2 Soll-Konzept

Im Soll-Zustand liegt eine datenbasierte Analyse der Durchlaufzeiten vor. Sie zeigt, wo Verzögerungen entstehen und welche Ursachen sie haben. Dafür sind folgende Schritte geplant:

- Die benötigten Daten auswählen, auf Vollständigkeit und Plausibilität prüfen und aufbereiten.

- Die Durchlaufzeiten der einzelnen Prozessschritte und geeignete Kennzahlen berechnen. Die genaue Auswahl der Kennzahlen folgt in Kapitel 4.2.
- Zusammenhänge zwischen langen Durchlaufzeiten und Merkmalen der Lieferungen (Lieferant, Warenart, Wochentag) mit einer Korrelationsanalyse und einem einfachen Regressionsmodell untersuchen.
- Die Ergebnisse mit Diagrammen darstellen und interpretieren.
- Verbesserungsmaßnahmen entwickeln und nach Nutzen und Wirtschaftlichkeit bewerten (Kosten-Nutzen-Betrachtung und Amortisation).
- Die Ergebnisse und die Kundendokumentation an den Auftraggeber übergeben.

Die Lösung muss diese Kernanforderungen erfüllen:

- Die Analyse ist nachvollziehbar und kann mit neuen Daten wiederholt werden (Jupyter Notebook).
- Die Ergebnisse sind für den Fachbereich verständlich (einfache Diagramme, Nutzen in Euro).
- Die Originaldaten werden nicht verändert.
- Es werden keine personenbezogenen Daten ausgewertet.

Der Ist-Soll-Vergleich in Kürze:

- Datenauswertung: Ist – keine zusammenhängende Auswertung. Soll – strukturierte Analyse mit Kennzahlen und Statistik.
- Wissen über Verzögerungen: Ist – Vermutungen. Soll – belegte Ursachen.
- Entscheidungsgrundlage: Ist – fehlt. Soll – bewertete Verbesserungsvorschläge mit Kosten und Nutzen.

Was nicht zum Projekt gehört, steht in der Abgrenzung in Kapitel 1.2.

2.3 Stakeholder-Analyse

Das Projektumfeld und die Schnittstellen sind in Kapitel 1.1 und 1.2 beschrieben. Dieses Kapitel ergänzt eine kurze Stakeholder-Analyse. Stakeholder sind Personen und Gruppen, die ein Interesse am Projekt haben oder das Projekt beeinflussen. Tabelle 2 zeigt ihre Erwartungen und den geplanten Umgang. Einfluss und Interesse sind mit hoch, mittel oder gering bewertet.

Stakeholder	**Rolle und Erwartung**	**Einfluss / Interesse**	**Umgang im Projekt**
Auftraggeber (Leitung Wareneingang)	Trifft Entscheidungen über Verbesserungen, nimmt die Ergebnisse ab. Erwartet klare Ergebnisse und wirtschaftlichen Nutzen.	hoch / hoch	Eng einbinden: Anforderungen am Anfang abstimmen, Ergebnisse am Ende übergeben.
Ansprechpartner Fachbereich Wareneingang	Beantwortet die Fragen zu Prozess und Daten. Erwartet praxisnahe Vorschläge.	mittel / hoch	Regelmäßig einbinden: Rückfragen zu Prozessschritten und zu Auffälligkeiten in den Daten.
Mitarbeitende Wareneingang und Einlagerung	Sind von den Verbesserungen betroffen. Mögliche Sorge: mehr Kontrolle oder mehr Arbeit.	mittel / hoch	Informieren: Ergebnisse einfach erklären. Es werden nur Prozessdaten ausgewertet, keine einzelnen Personen.

Tabelle 2: Stakeholder-Analyse

Den größten Einfluss hat der Auftraggeber. Deshalb wird der Auftraggeber bei den Anforderungen und bei der Übergabe eng eingebunden. Die Mitarbeitenden werden über die Ergebnisse informiert. Ihre mögliche Sorge wird berücksichtigt, weil keine einzelnen Personen ausgewertet werden.

2.4 Wirtschaftlichkeitsbetrachtung (Kosten, Nutzen, Amortisation)

Dieses Kapitel bewertet die Wirtschaftlichkeit des Projekts. Die Stundensätze und Mengen sind Annahmen (Planwerte).

Make-or-Buy-Entscheidung. Für die Analyse gibt es zwei Möglichkeiten: Der Projektbearbeiter führt sie selbst durch (Make), oder das Unternehmen kauft eine Process-Mining-Software oder eine externe Analyse (Buy). Ein Kauf verursacht Lizenz- oder Dienstleistungskosten, und für das Projekt gibt es kein Budget. Die Prozessdaten liegen als Dateien vor und sind für eine Analyse mit Python gut geeignet. Das nötige Wissen ist durch die Umschulung vorhanden. Deshalb wurde die Eigenanalyse gewählt.

Projektkosten. Die Projektkosten bestehen aus den Personalkosten und einer Pauschale für Arbeitsplatz und IT. Lizenzkosten entstehen nicht: Python, Jupyter Notebook und draw.io sind kostenlos, und Excel ist im Unternehmen schon vorhanden. Die 40 Stunden sind die Arbeitszeit des Projektbearbeiters. Sie entsprechen der Prüfungszeit und werden nicht überschritten. Die Teilnahme des Projektbearbeiters an den Gesprächen ist in diesen 40 Stunden enthalten (siehe Zeitplanung in Kapitel 3.3). Zusätzlich nehmen andere Personen Zeit für das Projekt in Anspruch: Der Auftraggeber nimmt 1,5 Stunden teil (Anforderungsgespräch 1 Stunde, Ergebnisbesprechung 0,5 Stunden). Der Ansprechpartner im Wareneingang beantwortet Rückfragen in etwa 2 Stunden. Diese Zeiten gehören nicht zu den 40 Stunden, werden aber bei den Projektkosten berücksichtigt. Tabelle 3 zeigt die Kosten.

Position	**Zeit, h**	**Stundensatz, € / h**	**Kosten, €**
Projektbearbeiter	40	25,00	1000,00
Auftraggeber (Leitung Wareneingang)	1,5	60,00	90,00
Ansprechpartner Fachbereich Wareneingang	2	40,00	80,00
Arbeitsplatz und IT (Pauschale)	43,5	10,00	435,00
Gesamtkosten			**1605,00**

Tabelle 3: Projektkosten

Nutzen. Der Nutzen entsteht, wenn der Auftraggeber die Verbesserungsvorschläge später umsetzt. Dann brauchen die Mitarbeitenden weniger Zeit pro Lieferung, zum Beispiel durch weniger Suchen und weniger Nacharbeit. Für die Berechnung gelten diese Annahmen: Im Wareneingang kommen etwa 35 Lieferungen pro Arbeitstag an. Bei 20 Arbeitstagen sind das 700 Lieferungen pro Monat. Der Stundensatz einer Fachkraft im Wareneingang beträgt 19,00 €. Es werden zwei Fälle gerechnet: eine vorsichtige Einsparung von 5 Minuten und eine erwartete Einsparung von 10 Minuten pro Lieferung. Die Werte sind Planwerte. Sie werden nach der Analyse in Kapitel 7.3 mit den Ergebnissen verglichen.

Amortisationsdauer. Die Amortisationsdauer zeigt, nach wie vielen Monaten die Einsparung die Projektkosten deckt. Die Formel lautet: Amortisationsdauer = Projektkosten ÷ Einsparung pro Monat. Tabelle 4 zeigt die Rechnung.

Größe	**Vorsichtiger Fall**	**Erwarteter Fall**
Lieferungen pro Monat	700	700
Eingesparte Zeit pro Lieferung	5 Minuten	10 Minuten
Eingesparte Arbeitszeit pro Monat	58,3 h	116,7 h
Stundensatz Fachkraft	19,00 €/h	19,00 €/h
Einsparung pro Monat	1108,33 €	2216,67 €
Projektkosten	1605,00 €	1605,00 €
Amortisationsdauer	ca. 1,4 Monate	ca. 0,7 Monate

Tabelle 4: Nutzen und Amortisationsdauer

Im vorsichtigen Fall amortisiert sich das Projekt nach etwa 1,4 Monaten, im erwarteten Fall nach etwa 0,7 Monaten. Die Kosten für die Umsetzung der Vorschläge sind nicht enthalten. Sie werden bei jedem Vorschlag einzeln bewertet. Die Rechnung ist deshalb ein erster Richtwert.

Nicht-monetäre Vorteile. Der Wareneingang erhält eine Entscheidungsgrundlage aus Daten statt aus Vermutungen. Kürzere Durchlaufzeiten verbessern die Abläufe in den folgenden Prozessen

und die Termintreue gegenüber den Kunden. Die Analyse kann später mit neuen Daten wiederholt werden.

2.5 Schutzbedarfsanalyse (Datenschutz und Datensicherheit)

In diesem Kapitel wird beschrieben, wie wichtig der Schutz der Daten im Projekt ist und welche Risiken für Datenschutz und Datensicherheit bestehen. Die Bewertung basiert auf den drei Schutzzielen Vertraulichkeit, Integrität und Verfügbarkeit. Der Schutzbedarf wird in die Stufen normal, hoch und sehr hoch eingeteilt. Diese Einteilung orientiert sich am BSI-Standard 200-2 des Bundesamts für Sicherheit in der Informationstechnik (BSI), siehe Kapitel 10.

Datenschutz (DSGVO). Die DSGVO gilt für personenbezogene Daten, also für Angaben, die sich auf eine bestimmte Person beziehen (Art. 4 Nr. 1 DSGVO). Die Prozessdaten im Projekt enthalten solche Angaben nicht. Sie bestehen aus synthetischen Zeitstempeln und Merkmalen der Lieferungen, zum Beispiel Lieferant, Warenart und Wochentag. Mitarbeitende werden nicht ausgewertet. Trotzdem werden zwei Grundsätze der DSGVO beachtet (Art. 5 DSGVO): Datenminimierung (nur Daten verwenden, die für die Analyse nötig sind) und Zweckbindung (Daten nur für diese Analyse nutzen). Bei echten Betriebsdaten müssten Namen von Mitarbeitenden vorher entfernt oder anonymisiert werden.

Schutzbedarf: Tabelle 5 zeigt den Schutzbedarf für jedes Schutzziel.

Schutzziel	Schutzbedarf	Begründung	Maßnahme
Vertraulichkeit	normal	Die Daten enthalten keine personenbezogenen Angaben und keine Betriebsgeheimnisse.	Daten nur im Projektordner speichern. Zugriff nur für den Projektbearbeiter.
Integrität	hoch	Falsche oder veränderte Zeitstempel führen zu falschen Ergebnissen und zu falschen Verbesserungsvorschlägen.	Originaldaten schreibgeschützt aufbewahren und nur mit Kopien arbeiten. Datenqualität prüfen (Kapitel 5.1).
Verfügbarkeit	normal	Der Betrieb des Wareneingangs ist nicht betroffen. Verlust der Daten kostet nur Projektzeit.	Tägliche Sicherung des Projektordners auf einem zweiten Datenträger.

Tabelle 5: Schutzbedarfsanalyse

Der Schutzbedarf ist insgesamt normal. Nur die Integrität ist hoch, weil die Qualität der Daten über die Qualität der Ergebnisse entscheidet.

Risikoanalyse. Tabelle 6 zeigt die wichtigsten Risiken für Datenschutz und Datensicherheit. Wahrscheinlichkeit und Auswirkung sind mit gering, mittel oder hoch bewertet. Projektrisiken wie Zeit und Termine werden in Kapitel 3.4 behandelt.

Risiko	Wahrscheinlichkeit	Auswirkung	Maßnahme
Verlust oder Beschädigung der Daten (Datei gelöscht, Notebook defekt)	mittel	mittel	Tägliche Sicherung des Projektordners. Originaldaten bleiben unverändert.
Unbefugter Zugriff auf die Daten (Notebook verloren)	gering	mittel	Passwortschutz und verschlüsselte Festplatte. Bildschirm bei Abwesenheit sperren.
Falsche Ergebnisse durch fehlerhafte oder veränderte Daten	mittel	hoch	Datenqualitätsprüfung, schreibgeschützte Originaldaten, nachvollziehbare Berechnungen im Notebook, Validierung der Ergebnisse.
Weitergabe von Daten an Dritte (in Dokumentation, Präsentation oder KI-Tools)	gering	mittel	Nur synthetische Daten in Dokumentation und Präsentation verwenden. Ergebnisse nur an den Auftraggeber übergeben.

Tabelle 6: Risikoanalyse

Mit den beschriebenen Maßnahmen sind die Restrisiken gering. Die Maßnahmen verursachen keine zusätzlichen Kosten, weil sie mit vorhandenen Mitteln umgesetzt werden (Passwortschutz, verschlüsselte Festplatte, Sicherung auf einen zweiten Datenträger).

3 Projektplanung

3.1 Projektziele (fachlich, organisatorisch, zeitlich)

Das Hauptziel des Projekts lautet: Die Durchlaufzeiten im Wareneingang werden anhand von Prozessdaten analysiert. Verzögerungen und ihre Ursachen werden erkannt, und daraus werden wirtschaftlich bewertete Verbesserungsvorschläge abgeleitet. Dieses Hauptziel wird in fachliche, organisatorische und zeitliche Ziele aufgeteilt.

Fachliche Ziele:

- Die Prozessdaten werden auf Vollständigkeit und Plausibilität geprüft und bereinigt (Datenqualität).
- Die Durchlaufzeiten der einzelnen Prozessschritte und geeignete Kennzahlen werden berechnet.
- Zusammenhänge zwischen langen Durchlaufzeiten und Merkmalen der Lieferungen (Lieferant, Warenart, Wochentag) werden mit Korrelation und Regression untersucht.
- Die Ergebnisse werden in verständlichen Diagrammen dargestellt.
- Es werden Verbesserungsvorschläge entwickelt und nach Nutzen und Wirtschaftlichkeit bewertet (Kosten-Nutzen-Betrachtung, Amortisation).

Organisatorische Ziele:

- Der Auftraggeber erhält eine Entscheidungsgrundlage und eine Kundendokumentation mit einer Anleitung zur Auswertung.
- Die Originaldaten bleiben unverändert. Produktive Systeme der MainLogistik GmbH werden nicht verändert.
- Alle Quellen und KI-Hilfsmittel werden vollständig angegeben.

Zeitliche Ziele:

- Der Zeitrahmen von 40 Stunden wird eingehalten. Für die Dokumentation sind höchstens 6 Stunden geplant.
- Die Durchführung findet vom 12.04. bis 23.04.2027 statt.
- Die Projektdokumentation wird bis zum 14.05.2027 im Online-Portal der IHK eingestellt (Frist: 15.05.2027).

3.2 Vorgehensmodell (Wasserfallmodell)

Das Projekt wird nach dem Wasserfallmodell durchgeführt. Beim Wasserfallmodell folgen die Phasen nacheinander. Eine neue Phase beginnt erst, wenn die vorherige Phase abgeschlossen ist. Die Phasen sind: Analyse, Planung, Datenvorbereitung, Datenanalyse, Auswertung, Optimierung, Qualitätssicherung, Projektabschluss und Projektdokumentation. Die Zeiten stehen in Kapitel 3.3.

Begründung der Wahl:

- Klare Anforderungen: Thema, Ziel und Zeitrahmen (40 Stunden) sind im Projektantrag festgelegt und werden vom Prüfungsausschuss genehmigt. Große Änderungen während der Durchführung sind nicht vorgesehen.
- Logischer Ablauf: Die Arbeitsschritte sind voneinander abhängig und folgen einer festen Reihenfolge. Ohne geprüfte Daten ist keine Analyse möglich, und ohne Analyse gibt es keine Verbesserungsvorschläge.

- Ein-Personen-Projekt: Scrum braucht ein Team mit Rollen (Product Owner, Scrum Master, Entwicklungsteam), Sprints und regelmäßige Meetings. Das passt nicht zu einem Projekt mit einer Person und 40 Stunden.
- Festes Projektende: Kanban eignet sich für laufende Aufgaben ohne festen Endtermin. Dieses Projekt hat einen festen Endtermin.
- Abnahme: Der Auftraggeber nimmt die Ergebnisse am Ende ab. Dafür sind klare Ergebnisse pro Phase hilfreich.

Nachteil und Gegenmaßnahmen. Beim Wasserfallmodell sind Änderungen in späteren Phasen schwierig. Deshalb werden die Anforderungen am Anfang mit dem Auftraggeber abgestimmt (Kapitel 2.3). Am Ende jeder Phase werden die Ergebnisse geprüft (Meilensteine, Kapitel 3.4). Abweichungen vom Plan werden im Soll-Ist-Vergleich dokumentiert (Kapitel 5.5 und 8.2).

3.3 Ablauf- und Zeitplanung

Der Zeitrahmen des Projekts beträgt 40 Stunden. Das Projekt wird vom 12.04. bis 23.04.2027 an zehn Arbeitstagen (Montag bis Freitag) durchgeführt. Pro Arbeitstag sind 4 Stunden geplant. Die Phasen folgen nach dem Wasserfallmodell nacheinander (Kapitel 3.2). Tabelle 7 zeigt die grobe Zeitplanung. Die detaillierte Zeitplanung mit allen Arbeitspaketen steht in Anlage 1.

Projektphase	Geplante Zeit
Analyse	4 h
Planung	4 h
Datenvorbereitung	7 h
Datenanalyse	8 h
Auswertung	4 h
Optimierung	4 h
Qualitätssicherung	2 h
Projektabschluss	1 h
Projektdokumentation	6 h
Gesamt	40 h

Tabelle 7: Grobe Zeitplanung

Die Zeiten sind Planwerte aus dem Projektantrag. Den größten Teil der Zeit brauchen die Datenvorbereitung (7 Stunden) und die Datenanalyse (8 Stunden). Zusammen sind das 15 Stunden, also 37,5 % der Gesamtzeit. Der Grund ist, dass die Datenqualität die Qualität der Ergebnisse bestimmt (siehe Kapitel 2.5). Für die Projektdokumentation sind 6 Stunden geplant. Das sind 15 % der Gesamtzeit und das von der IHK erlaubte Maximum.
Abbildung 1 zeigt den zeitlichen Ablauf der Phasen als Gantt-Diagramm.
Weil alle Phasen nacheinander laufen, braucht jede Phase das Ergebnis der vorherigen. Deshalb liegen alle Phasen auf dem kritischen Pfad. Das ist der Weg durch den Plan, bei dem jede Verspätung das Projektende verschiebt. Es gibt keine Pufferzeit. Die Risiken dazu und die Gegenmaßnahmen stehen in Kapitel 3.4.

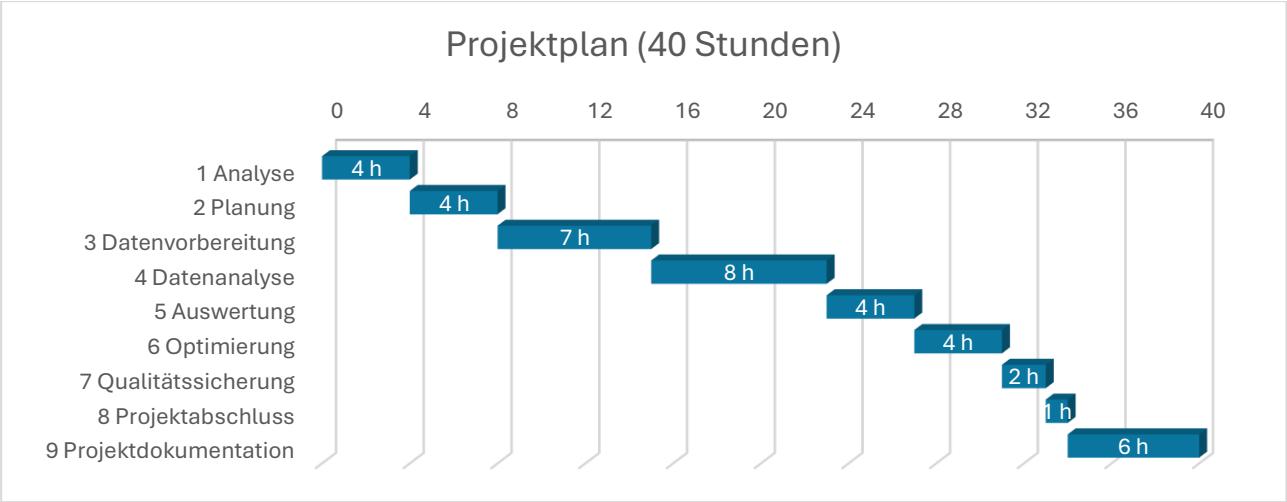


Abbildung 1: Gantt-Diagramm der Projektphasen

3.4 Ressourcen-, Meilenstein- und Risikoplanung

Ressourcenplanung. Für das Projekt werden Personal, Hardware, Software und Daten benötigt. Tabelle 8 zeigt die Übersicht. Alle Werkzeuge sind kostenlos oder im Unternehmen schon vorhanden. Es müssen keine Lizenzen und keine Hardware gekauft werden. Die Personalkosten stehen in Kapitel 2.4 (Tabelle 3).

Kategorie	Ressource	Einsatz
Personal	Projektbearbeiter	40 Stunden
Personal	Auftraggeber (Leitung Wareneingang)	1,5 Stunden (Anforderungsgespräch, Ergebnisbesprechung)
Personal	Ansprechpartner Fachbereich	2 Stunden (Fragen zu Prozess und Daten)
Hardware	Arbeitsplatz mit Notebook	vorhanden
Software	Python, Jupyter Notebook, Pandas, Matplotlib, SciPy/Statsmodels	kostenlos (Open Source)
Software	MS Office, draw.io	vorhanden bzw. kostenlos
Daten	Synthetische Prozessdaten (CSV-Datei)	vom Auftraggeber bereitgestellt

Tabelle 8: Ressourcenplanung

Meilensteinplanung. Ein Meilenstein ist ein wichtiges Zwischenziel. An jedem Meilenstein wird geprüft, ob das Ergebnis der Phase die Kriterien erfüllt. Erst danach beginnt die nächste Phase. Die Termine passen zum Gantt-Diagramm (Abbildung 1). Tabelle 9 zeigt die Meilensteine. Das Projekt endet am 23.04.2027. Die Dokumentation wird danach bis zum 14.05.2027 im Online-Portal der IHK eingestellt.

Nr	Meilenstein	Termin	Prüfkriterium
M1	Anforderungen abgestimmt	12.04.2027	Ziel und Anforderungen sind mit dem Auftraggeber geklärt.
M2	Datensatz bereinigt	15.04.2027	Fehlende Werte und unmögliche Zeiten sind behandelt, und die Bereinigung ist dokumentiert.
M3	Analyse abgeschlossen	19.04.2027	Es gibt Kennzahlen, Korrelation und Regressionsmodell.
M4	Verbesserungen bewertet	21.04.2027	Jeder Vorschlag hat eine Kosten-Nutzen-Betrachtung und eine Amortisationsrechnung.
M5	Ergebnisse geprüft und übergeben	22.04.2027	Die Ergebnisse wurden validiert, und der Auftraggeber hat sie erhalten.
M6	Dokumentation fertig	23.04.2027	Projekt- und Kundendokumentation sind vollständig und geprüft.

Tabelle 9: Meilensteine

Risikoplanung. Risiken sind Ereignisse, die den Projekterfolg gefährden können. Die Risiken für Datenschutz und Datensicherheit stehen in Kapitel 2.5. Hier stehen die Projektrisiken. Wahrscheinlichkeit und Auswirkung werden mit gering, mittel oder hoch bewertet (Tabelle 10).

Risiko	Wahrscheinlichkeit	Auswirkung	Gegenmaßnahme
Die Datenqualität ist schlechter als erwartet (viele fehlende oder falsche Werte).	mittel	hoch	Für die Datenvorbereitung sind 7 Stunden geplant. Die Regeln zur Bereinigung werden dokumentiert. Bei großen Lücken Rücksprache mit dem Auftraggeber.
Der Zeitplan ist zu knapp, es gibt keinen Puffer.	mittel	hoch	Täglicher Vergleich von Plan und Ist (Kapitel 5.5). Während des Projekts werden Notizen und Screenshots gesammelt. Diese Zeit ist in den Arbeitspaketen enthalten. Zusatzauswertungen entfallen zuerst.
Es gibt keinen starken statistischen Zusammenhang.	mittel	mittel	Auch „kein Zusammenhang“ ist ein Ergebnis. Es wird ehrlich dargestellt. Verbesserungen werden dann aus den Wartezeiten der Prozessschritte abgeleitet.
Der Ansprechpartner ist nicht erreichbar.	gering	mittel	Termine werden am Projektstart fest vereinbart. Fragen werden gesammelt gestellt.
Daten oder Notebook gehen verloren.	mittel	mittel	Die Original-CSV bleibt unverändert. Es wird täglich eine Sicherung mit Datum gespeichert.

Tabelle 10: Projektrisiken

4 Entwurf

4.1 Datenmodell und Datenquellen

Datenquelle. Die Analyse nutzt eine CSV-Datei mit Prozessdaten des Wareneingangs (wareneingang_roh.csv). Die Daten sind synthetisch, aber realistisch aufgebaut. Im Übungsprojekt ersetzt ein Python-Skript den Export aus dem Betrieb. Das Skript wurde mit Unterstützung eines KI-Hilfsmittels erstellt (Kapitel 9). Es arbeitet mit einem festen Startwert, damit die Daten wiederholbar sind. In einem echten Projekt käme die Datei aus dem Lagerverwaltungssystem. Die Daten enthalten keine personenbezogenen Angaben, also keine Mitarbeitenden, Fahrer oder Kennzeichen.

Datenumfang. Die Datei enthält Lieferungen vom 04.01.2027 bis 31.03.2027 (1. Quartal, 61 Arbeitstage). Das sind rund 2.100 Zeilen, im Mittel 34 Lieferungen pro Tag. Das passt zur Annahme von 35 Lieferungen pro Tag (Kapitel 2.1).

Datenmodell. Eine Zeile steht für eine Lieferung. Alle Daten liegen in einer Tabelle. Das ist für eine einmalige Analyse mit etwa 2.100 Zeilen einfach und ausreichend. Tabelle 11 zeigt die Felder.

Zeitstempel. Die Ankunft der Ware ist der Startpunkt. Die vier Zeitstempel danach zeigen jeweils das Ende eines Prozessschritts (Annahme, Kontrolle, Erfassung, Vorbereitung für die Einlagerung). Die Zeit eines Schritts ist die Differenz zum vorherigen Zeitstempel. Sie enthält Warte- und Bearbeitungszeit. Beide Zeiten getrennt zu messen ist mit diesen Daten nicht möglich. Das wird bei der Interpretation beachtet.

Abgeleitete Merkmale. In Kapitel 5.1 werden diese Merkmale berechnet: Wochentag und Ankunftsstunde (aus ts_ankunft), die vier Schrittzeiten in Minuten und die Gesamtdurchlaufzeit (ts_einlagerung_bereit minus ts_ankunft).

Schutz der Daten. Die Originaldatei bleibt schreibgeschützt. Alle Auswertungen laufen mit Kopien (Kapitel 2.5).

Feld	Bedeutung	Datentyp	Beispiel
lieferung_id	Eindeutige Nummer der Lieferung	Text	L-2027-00001
lieferant_id	Kennung des Lieferanten (8 Lieferanten)	Text	LF02

warenart	Art der Ware (5 Kategorien)	Text	Kühlware
anzahl_paletten	Zahl der Paletten	Ganzzahl	12
anzahl_positionen	Zahl der Positionen auf dem Lieferschein	Ganzzahl	19
avisiert	Lieferung vorher angekündigt (ja/nein)	Text	ja
ts_ankunft	Ware kommt am Tor an	Zeitstempel	2027-01-04 06:28:49
ts_annahme	Annahme abgeschlossen	Zeitstempel	2027-01-04 07:02:19
ts_kontrolle	Kontrolle abgeschlossen	Zeitstempel	2027-01-04 07:27:43
ts_erfassung	Erfassung im System abgeschlossen	Zeitstempel	2027-01-04 07:51:27
ts_einlagerung_bereit	Ware ist bereit für die Einlagerung	Zeitstempel	2027-01-04 08:08:59

Tabelle 11: Datenfelder der Rohdaten (wareneingang_roh.csv)

4.2 Analysemethoden und technische Entscheidungen

In diesem Kapitel stehen die technischen Entscheidungen, die Kennzahlen und die statistischen Verfahren. Sie wurden in der Planungsphase ausgewählt (Kapitel 3.3, Arbeitspaket 2.2). Die Make-or-Buy-Entscheidung steht in Kapitel 2.4.

Technische Entscheidungen. Tabelle 12 zeigt die Werkzeuge und die Gründe.

Werkzeug	Aufgabe	Alternative	Begründung
Python mit Jupyter Notebook	Analyse und Dokumentation des Vorgehens	Excel, Power BI	Code, Ergebnisse und Erklärungen stehen zusammen. Die Analyse ist nachvollziehbar und mit neuen Daten wiederholbar. Kostenlos.
Pandas	Daten einlesen, bereinigen, berechnen	Excel-Formeln	Die Regeln stehen im Code und lassen sich wiederholen. Excel dient nur zur Sichtung der Rohdaten.
SciPy	Korrelation, statistische Tests	Excel	Enthält die benötigten Verfahren (Spearman, Kruskal-Wallis). Nicht direkt in Excel verfügbar.
Statsmodels	Regression	scikit-learn	Gibt direkt statistische Kennzahlen aus (Koeffizienten, p-Werte, R^2). Scikit-learn ist mehr auf Vorhersagen ausgerichtet.
Matplotlib	Diagramme	Seaborn, Power BI	Im Antrag vorgesehen. Volle Kontrolle über die Diagramme. Kostenlos.
draw.io	Prozess- und Datenfluss-Darstellung	Visio	Kostenlos und ausreichend.

Tabelle 12: Technische Entscheidungen

Kennzahlen. Tabelle 13 zeigt die Kennzahlen. Die Durchlaufzeiten sind rechtsschief: Es gibt viele normale und wenige sehr lange Lieferungen. Einzelne lange Werte erhöhen den Mittelwert stark, den Median aber kaum. Deshalb werden Median und 90-%-Perzentil zusätzlich zum Mittelwert verwendet.

Kennzahl	Berechnung	Aussage
Gesamtdurchlaufzeit	ts_einlagerung_bereit − ts_ankunft, in Minuten	Hauptkennzahl des Projekts
Schrittzeit	Differenz zweier benachbarter Zeitstempel (4 Schritte)	Wo vergeht die Zeit?
Anteil eines Schritts	Mittlere Schrittzeit ÷ mittlere Gesamtzeit, in %	Größter Zeitblock
Median	Mittlerer Wert: 50 % der Lieferungen sind schneller	Typische Lieferung, stabil bei Ausreißern
90-%-Perzentil (P90)	90 % der Lieferungen sind schneller	Langsame Lieferungen
Median je Gruppe	Median nach Lieferant, Warenart, Wochentag, angekündigt	Vergleich von Gruppen

Tabelle 13: Kennzahlen

Statistische Verfahren. Die Merkmale der Lieferungen haben zwei Typen. Zahlenmerkmale sind Paletten, Positionen und Ankunftsstunde. Kategorien sind Lieferant, Warenart, Wochentag und „angekündigt“. Dafür werden drei Verfahren genutzt (Quellen: Kapitel 10):

- Korrelation nach Spearman (Zahlenmerkmale). Sie misst, ob höhere Werte eines Merkmals zu längeren Durchlaufzeiten gehören (Wert von −1 bis +1). Sie nutzt Ränge und ist bei schiefen Daten und Ausreißern stabiler als die Korrelation nach Pearson.
- Gruppenvergleich (Kategorien). Eine Korrelation ist hier nicht sinnvoll, weil Kategorien keine Reihenfolge haben. Gezeigt werden der Median je Gruppe und ein Boxplot. Der Kruskal-Wallis-Test prüft, ob die Unterschiede zwischen den Gruppen zufällig sein können.
- Multiple lineare Regression (Statsmodels). Sie ist ein einfaches mathematisches Vorhersagemodell. Zielgröße ist die Gesamtdurchlaufzeit in Minuten. Kategorien gehen als Dummy-Variablen (0/1) ins Modell ein. Die Koeffizienten zeigen, um wie viele Minuten sich die Durchlaufzeit verändert, wenn ein bestimmtes Merkmal vorhanden ist (bei Kategorien: im Vergleich zur Referenzkategorie) und alle anderen Merkmale gleichbleiben. Die Positionen werden nicht berücksichtigt, weil sie stark mit der Anzahl der Paletten zusammenhängen (Multikollinearität). Das wird in Kapitel 5.2 geprüft.

Als Signifikanzniveau gilt 5 % ($p < 0{,}05$). Die Güte des Modells zeigt das Bestimmtheitsmaß R^2. Ein statistischer Zusammenhang ist kein Beweis für eine Ursache. Deshalb werden die Ergebnisse mit dem Ansprechpartner aus dem Fachbereich besprochen. Die Diagramme (Histogramm, Boxplot, Balkendiagramm, Streudiagramm) folgen in Kapitel 5.3.

4.3 Schnittstellen und Datenflüsse

Dieses Kapitel zeigt, wie die Daten im Projekt von der Quelle bis zum Auftraggeber fließen. Abbildung 2 zeigt den Weg der Daten. Die Nummern 1 bis 5 sind die Verarbeitungsschritte. Die Schritte 1 und 2 gehören zu Kapitel 5.1, Schritt 3 zu Kapitel 5.2, Schritt 4 zu Kapitel 5.3 und Schritt 5 zu Kapitel 5.4. Die Nummern D1 bis D6 sind die Datenflüsse. Tabelle 14 beschreibt sie.

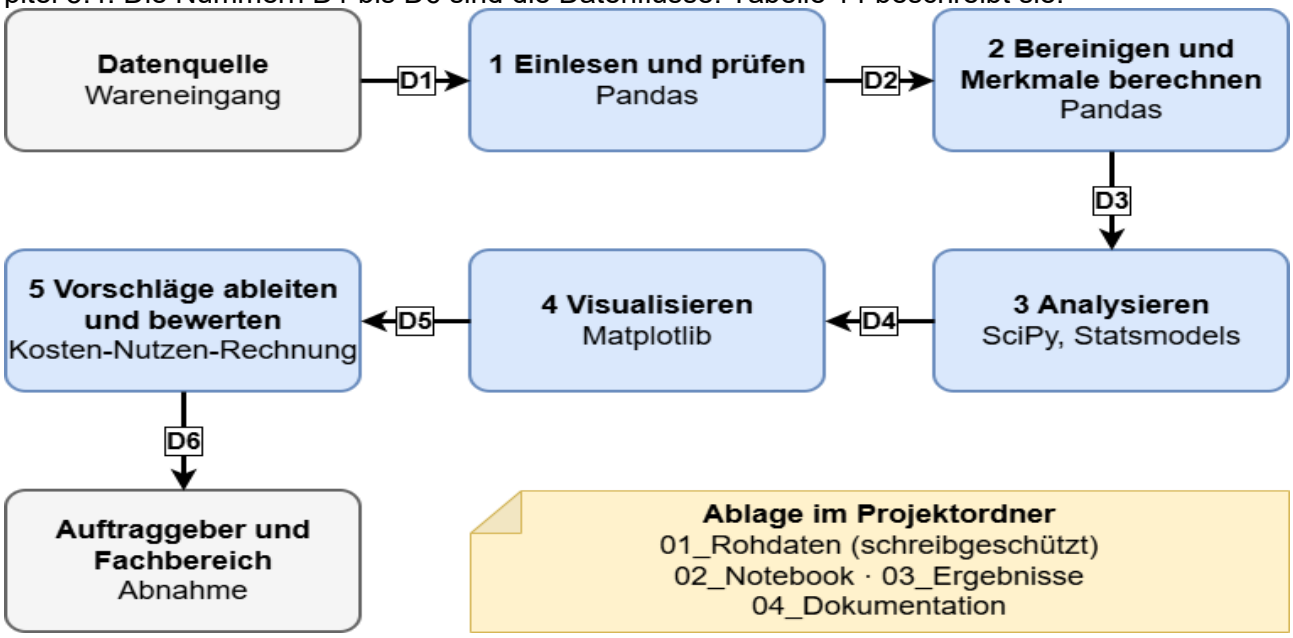


Abbildung 2: Datenfluss des Projekts

Nr.	Von ⇒ Nach	Daten	Format und Ablage
D1	Datenquelle ⇒1	Rohdaten der Lieferungen	CSV, Ordner 01_Rohdaten, schreibgeschützt
D2	1 ⇒ 2	Geprüfte Daten und Liste der Datenfehler	Pandas-Tabelle im Arbeitsspeicher
D3	2 ⇒ 3	Bereinigte Daten mit abgeleiteten Merkmalen	CSV, Ordner 03_Ergebnisse
D4	3 ⇒ 4	Kennzahlen, Testergebnisse, Regressionsmodell	Ergebnistabellen (CSV), Ordner 03_Ergebnisse
D5	4 ⇒ 5	Diagramme und Auswertung	PNG, Ordner 03_Ergebnisse

D6	5 ⇒ Auftraggeber	Verbesserungsvorschläge, Projekt- und Kundendokumentation	PDF, Ordner 04_Dokumentation

Tabelle 14: Datenflüsse

Schnittstellen. Es gibt keine Verbindung zu produktiven Systemen, keine Datenbank und keine Online-Schnittstelle (API). Der Austausch läuft nur über Dateien (CSV, PNG, PDF). Dazu kommt der persönliche Austausch: Der Ansprechpartner aus dem Fachbereich beantwortet fachliche Rückfragen zu den Daten. Der Auftraggeber nimmt die Ergebnisse ab (Kapitel 6.3).

Schutz und Wiederholbarkeit. Die Rohdaten (D1) werden nur gelesen und nie verändert. Alle weiteren Dateien entstehen als Kopien in eigenen Ordnern. Das Notebook kann von oben nach unten ausgeführt werden. Wenn die Rohdaten gleichbleiben, erzeugt es jedes Mal dieselben Ergebnisse.

5 Projektdurchführung

5.1 Datenaufbereitung

Dieses Kapitel beschreibt die Schritte 1 und 2 des Datenflusses (Abbildung 2). Alle Schritte liefen im Jupyter Notebook (Ordner 02_Notebook). Die Rohdatei wurde nur gelesen und nie verändert (Kapitel 4.3).

Daten einlesen. Die Datei hatte 2.109 Zeilen und 11 Spalten. Sie enthielt 2.099 verschiedene Lieferungen an 61 Arbeitstagen. Die fünf Zeitstempel wurden beim Einlesen als Datum und Uhrzeit erkannt.

Datenqualität prüfen. Für die Prüfung wurden sechs Regeln festgelegt (Tabelle 15). Jede Zeile bekam höchstens einen Fehlergrund, und zwar nach der Reihenfolge der Regeln.

Nr.	Regel	Begründung	Zeilen	Behandlung
1	Doppelte Zeile	Eine Lieferung darf nur einmal vorkommen.	10	entfernt (Original bleibt)
2	Fehlender Zeitstempel	Ohne alle fünf Zeitstempel kann man keine Schrittzeiten berechnen.	42	entfernt
3	Falsche Reihenfolge	Ein Schritt kann nicht enden, bevor der vorherige Schritt endet. In allen Fällen lag die Kontrolle vor der Annahme.	21	entfernt
4	Unmögliche Palettenzahl	Eine Lieferung hat 1 bis 33 Paletten (ein LKW lädt höchstens ca. 33 Euro-Paletten). Gefunden wurden die Werte 0 und 99.	6	entfernt
5	Ausreißer	Die Gesamtzeit ist länger als 8 Stunden. Der längste normale Wert ist 148 Minuten. Die Ware war erst am nächsten Tag „bereit“, das ist vermutlich ein Buchungsfehler.	10	entfernt
6	Schreibweise der Warenart	Jede Kategorie braucht eine einheitliche Schreibweise (z. B. „kuehlware“ oder „ KÜHLWARE“).	42	korrigiert

Tabelle 15: Datenqualitätsprüfung

Ergebnis. Insgesamt wurden 89 Zeilen entfernt (4,2 %). Es blieben 2.020 Zeilen (95,8 %). Das reicht für die Analyse. Die entfernten Zeilen stehen mit Grund in der Datei datenfehler_liste.csv (D2). Bei 42 Zeilen wurde nur die Schreibweise der Warenart korrigiert. Danach gab es genau fünf Warenarten.

Neue Merkmale. Aus den Zeitstempeln wurden diese Merkmale berechnet: Wochentag, Ankunftsstunde, vier Schrittzeiten in Minuten und die Gesamtdurchlaufzeit. Als Kontrolle wurde die Summe der vier Schrittzeiten mit der Gesamtzeit verglichen. Sie ist bei allen Zeilen gleich. Alle Gesamtzeiten liegen zwischen 34 und 148 Minuten. Die bereinigte Datei heißt wareneingang_bereinigt.csv (D3).

5.2 Datenanalyse

Die Analyse lief im selben Notebook weiter (Datenfluss, Schritt 3). Grundlage waren die 2.020 bereinigten Lieferungen. Zuerst wurden die Kennzahlen aus Tabelle 13 berechnet. Danach folgten die statistischen Verfahren.

Gesamtdurchlaufzeit. Eine Lieferung brauchte im Mittel 75,3 Minuten von der Ankunft bis „bereit zur Einlagerung“. Der Median lag bei 74,3 Minuten. 90 % der Lieferungen waren nach 97,8 Minuten oder früher fertig (P90). Die kürzeste Zeit war 33,7 Minuten, die längste 148,1 Minuten. Die Schiefe war 0,56. Die Verteilung ist also leicht rechtsschief: Es gibt etwas mehr sehr lange als sehr kurze Lieferungen. Wie stark einzelne lange Werte den Mittelwert verändern, zeigt ein Vergleich: Mit den 10 Ausreißern aus Kapitel 5.1 wäre der Mittelwert bei 82,4 Minuten gewesen (+7,1), der Median aber nur bei 74,4 Minuten (+0,1). Darum sind Median und P90 gute Kennzahlen.

Schrittzeiten. Tabelle 16 zeigt die vier Schritte. Die Annahme braucht am meisten Zeit, nämlich ein Drittel der Gesamtzeit (33,5 %). Zusammen mit der Kontrolle sind es 61 %.

Schritt	Mittelwert (Min.)	Median (Min.)	P90 (Min.)	Anteil (%)
Annahme	25,2	23,5	38,6	33,5
Kontrolle	20,7	18,9	31,4	27,5
Erfassung	13,6	13,1	19,5	18,1
Bereitstellung	15,7	15,3	21,5	20,9
Gesamt	**75,3**	**74,3**	**97,8**	**100**

Tabelle 16: Schrittzeiten und Anteil an der Gesamtzeit:

Vergleich der Gruppen. Tabelle 17 zeigt für jedes Merkmal die schnellste und die langsamste Untergruppe (Median der Gesamtdurchlaufzeit). Auffällig sind die Lieferanten LF03 und LF07, die Warenart Gefahrgut und die nicht avisierten Lieferungen. Die Wochentage unterscheiden sich nur wenig. Das sind erst beschreibende Werte. Ob die Unterschiede zufällig sein können und welches Merkmal wirklich wirkt, zeigen die statistischen Verfahren weiter unten in diesem Kapitel.

Merkmal	Schnellste Untergruppe	Langsamste Untergruppe	Unterschied (Min.)
Lieferant (8)	LF08: 64,4	LF03 und LF07: je 81,4	17,0
Warenart (5)	Sperrgut: 57,6	Gefahrgut: 82,4	24,8
Wochentag (5)	Donnerstag: 72,6	Montag: 76,8	4,2
Avisiert (2)	ja: 73,3	nein: 81,1	7,8

Tabelle 17: Median der Gesamtdurchlaufzeit je Gruppe (Minuten)

Korrelation nach Spearman. Tabelle 18 zeigt die Ergebnisse. Je mehr Paletten (r = 0,52) und je mehr Positionen (r = 0,54) eine Lieferung hat, desto länger dauert sie. Das ist ein mittlerer Zusammenhang. Die Ankunftsstunde hat keinen Einfluss (r = −0,03; p = 0,22). Paletten und Positionen hängen selbst eng zusammen (r = 0,74). Darum wurde die Regression mit und ohne Positionen gerechnet (siehe unten).

Gruppenvergleich (Kruskal-Wallis). Bei allen vier Kategorien sind die Unterschiede nicht zufällig (je-weils p < 0,001). Am stärksten wirkt die Warenart (H = 292,3). Danach folgen der Lieferant (H = 152,5), die Voranmeldung (H = 66,5) und der Wochentag (H = 25,9). Je größer H ist, desto größer sind die Unterschiede zwischen den Gruppen.

Merkmal	Verfahren	Wert	p-Wert
Anzahl Paletten	Spearman	r = 0,52	< 0,001
Anzahl Positionen	Spearman	r = 0,54	< 0,001
Ankunftsstunde	Spearman	r = −0,03	0,22
Warenart (5 Gruppen)	Kruskal-Wallis	H = 292,3	< 0,001
Lieferant (8 Gruppen)	Kruskal-Wallis	H = 152,5	< 0,001
Voranmeldung (2 Gruppen)	Kruskal-Wallis	H = 66,5	< 0,001
Wochentag (5 Gruppen)	Kruskal-Wallis	H = 25,9	< 0,001

Tabelle 18: Statistische Tests (Spearman und Kruskal-Wallis)

Regression. Ein Test zeigt nur, dass es einen Unterschied gibt. Er zeigt nicht, wie groß der Einfluss eines Merkmals ist, wenn alle anderen gleichbleiben. Das zeigt die Regression. Es wurden zwei

Modelle gerechnet. Modell A enthält Paletten, Ankunftsstunde, Lieferant, Warenart, Wochentag und Voranmeldung (R^2 = 0,532). Modell B enthält zusätzlich die Positionen (R^2 = 0,581). Der VIF-Wert zeigt, ob sich Merkmale zu stark überschneiden. Er ist bei allen Merkmalen kleiner als 3 (am höchsten: Paletten mit 2,96). Deshalb dürfen die Positionen ins Modell. Modell B wurde als Endmodell gewählt, weil es mehr erklärt (angepasstes R^2 0,577 statt 0,528). Es erklärt 58,1 % der Unterschiede in der Durchlaufzeit. Mit neuen Daten (20 % der Lieferungen, die nicht zum Rechnen des Modells genutzt wurden) erreicht es R^2 = 0,585 (Test T9, Kapitel 6.2). Die übrigen 41,9 % hängen von Dingen ab, die nicht in den Daten stehen.

Ergebnisse des Modells. Tabelle 19 zeigt die wichtigsten Wirkungen in Minuten. Vergleichsgruppe sind der Lieferant LF01, die Warenart Trockenware, der Montag und angekündigte Lieferungen. Beispiel: Eine Lieferung mit Gefahrgut dauert bei gleicher Menge, gleichem Lieferanten und gleichem Wochentag 21,0 Minuten länger als eine Lieferung mit Trockenware. Jede zusätzliche Palette verlängert die Zeit um 2,4 Minuten, jede zusätzliche Position um 1,5 Minuten. Die Ankunftsstunde hat keinen sicheren Einfluss (p = 0,17).

Merkmal	Wirkung (Min.)	95-%-Bereich	p-Wert
Jede zusätzliche Palette	+2,4	2,2 bis 2,7	< 0,001
Jede zusätzliche Position	+1,5	1,3 bis 1,7	< 0,001
Warenart Gefahrgut (statt Trockenware)	+21,0	18,9 bis 23,1	< 0,001
Warenart Elektronik	+14,6	13,0 bis 16,2	< 0,001
Warenart Kühlware	+8,7	7,3 bis 10,1	< 0,001
Lieferant LF07 (statt LF01)	+9,2	7,1 bis 11,2	< 0,001
Lieferant LF03 (statt LF01)	+7,3	5,6 bis 9,0	< 0,001
Nicht angekündigt (statt angekündigt)	+7,3	5,9 bis 8,7	< 0,001
Dienstag (statt Montag)	−4,5	−5,9 bis −3,0	< 0,001
Mittwoch (statt Montag)	−6,5	−8,0 bis −5,0	< 0,001
Ankunftsstunde (je Stunde später)	−0,1	−0,3 bis 0,1	0,17

Tabelle 19: Regressionsmodell B: Wirkung der Merkmale in Minuten

5.3 Auswertung und Visualisierung

Die Ergebnisse wurden in vier Diagrammen dargestellt (Datenfluss, Schritt 4). Sie sind bewusst einfach gehalten, weil der Auftraggeber nur geringe Vorkenntnisse in der Datenanalyse hat (Tabelle 1). Alle Achsen haben eine Beschriftung mit Einheit (Minuten). Die Diagramme liegen als PNG-Dateien im Ordner 03_Ergebnisse (D5).

Verteilung und Schritte. Abbildung 3 links zeigt die Verteilung der Gesamtdurchlaufzeit. Die meisten Lieferungen (62,9 %) brauchten 60 bis unter 90 Minuten. 19,3 % brauchten weniger als 60 Minuten und 17,8 % mindestens 90 Minuten. Die Verteilung hat einen Gipfel und einen längeren Schwanz nach rechts. Median (74,3 Min.) und P90 (97,8 Min.) sind als Linien eingezeichnet. Abbildung 3 rechts zeigt den Anteil der vier Schritte. Annahme und Kontrolle sind zusammen für 61 % der Zeit verantwortlich.

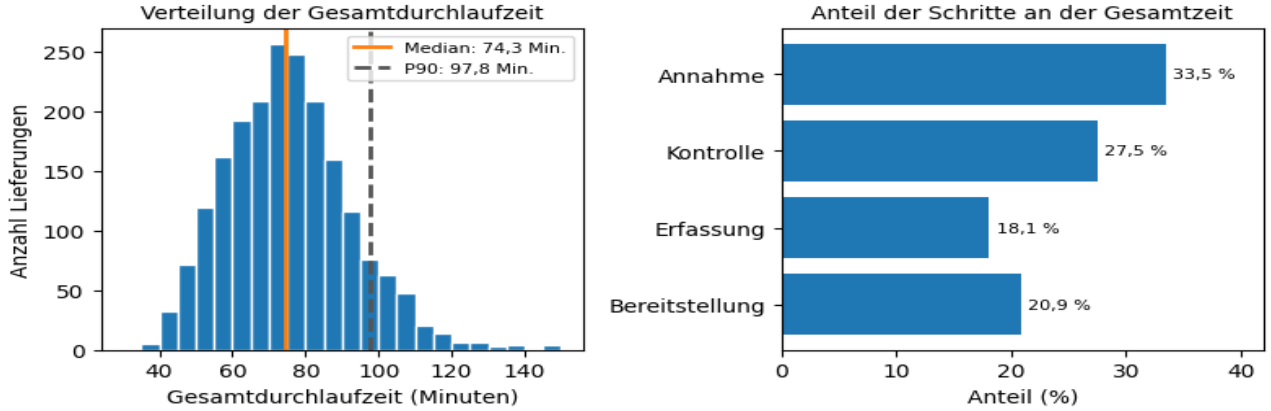


Abbildung 3: Verteilung der Gesamtdurchlaufzeit (links) und Anteil der Schritte an der Gesamtzeit (rechts)

Einflüsse. Abbildung 4 links zeigt je Warenart einen Boxplot. Der Kasten enthält die mittleren 50 % der Lieferungen, die Linie ist der Median. Sperrgut liegt deutlich niedriger (Median 57,6 Min.). Die anderen vier Warenarten liegen eng zusammen (Median 75,0 bis 82,4 Min.). Gefahrgut hat den höchsten Median. Die Punkte außerhalb der Whisker sind besonders lange Lieferungen. Das sind echte Werte, keine Fehler. Abbildung 4 rechts zeigt den Zusammenhang mit der Anzahl der Paletten. Mit mehr Paletten steigt die Zeit: Bei 1 Palette waren es im Mittel 56,8 Minuten, bei 13 Paletten 98,1 Minuten. Bei gleicher Palettenzahl streuen die Werte aber stark. Die Paletten erklären also nur einen Teil der Zeit (siehe R^2 in Kapitel 5.2).

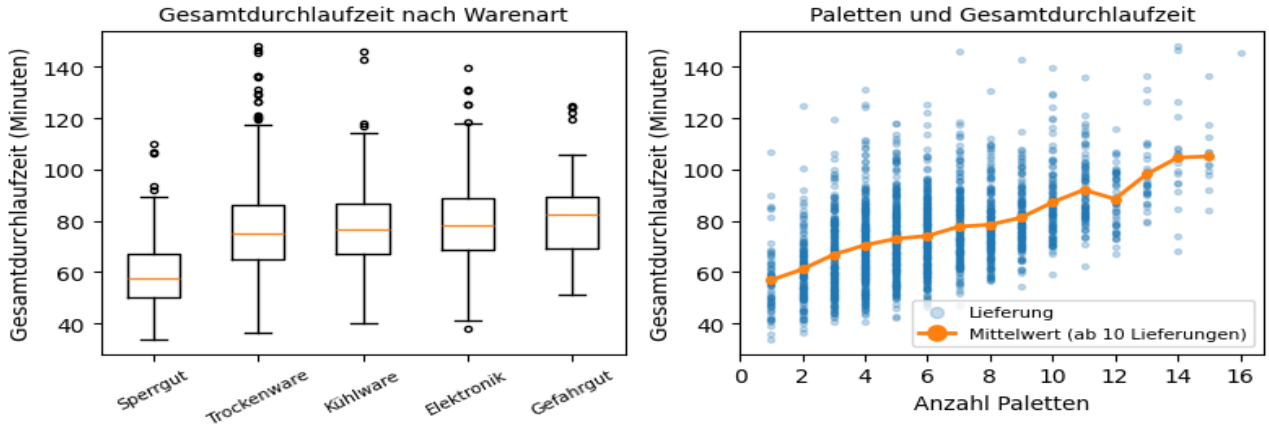


Abbildung 4: Gesamtdurchlaufzeit nach Warenart (links) und Zusammenhang mit der Anzahl der Paletten (rechts)

Interpretation. Aus den Diagrammen und den Tests ergeben sich drei Aussagen für den Fachbereich: (1) Die Annahme ist der größte Zeitblock. (2) Die Warenart wirkt auch bei gleicher Menge: Gefahrgut, Elektronik und Kühlware sind langsamer als Trockenware (Tabelle 19). Trockenware liegt trotzdem im Mittelfeld, weil dort im Mittel die meisten Paletten pro Lieferung ankommen (8,1 gegenüber 2,9 bis 6,0 bei den anderen Arten). (3) Lieferant, fehlende Voranmeldung und der Montag verlängern die Zeit zusätzlich. Auf diese Punkte kann der Betrieb Einfluss nehmen. Daraus entstehen die Verbesserungsvorschläge in Kapitel 5.4.

5.4 Verbesserungsvorschläge

Aus den Ergebnissen wurden Maßnahmen abgeleitet. Ein Vorschlag wurde nur gemacht, wenn der Betrieb Einfluss hat und die Daten einen Vergleichswert zeigen. Für die Warenart gibt es deshalb keinen Vorschlag: Gefahrgut braucht aus Sicherheitsgründen mehr Zeit. Die Kontrolle dauert dort im Mittel 14,7 Minuten länger als bei den anderen Warenarten. Es gibt keine Vergleichsgruppe mit gleicher Ware.

V1 Voranmeldung. Lieferungen ohne Voranmeldung (16,3 %) dauerten bei gleichen Merkmalen 7,3 Minuten länger. Die Zusatzzeit entsteht vor allem in der Annahme (im Mittel 8,8 Minuten länger). Vorschlag: Alle Lieferanten melden jede Lieferung mit einem Zeitfenster an.

V2 Lieferanten LF03 und LF07. Die beiden Lieferanten brauchten bei gleicher Menge, Warenart, Wochentag und Voranmeldung 7,3 bzw. 9,2 Minuten länger als LF01. Die Zusatzzeit entsteht in der Annahme (+7,1 Minuten) und in der Kontrolle (+3,8 Minuten). Die Ursache ist aus den Daten nicht erkennbar. Vorschlag: Mit beiden Lieferanten klären, woran es liegt (z. B. Lieferpapiere, Kennzeichnung der Paletten). Ziel ist das Niveau der anderen Lieferanten.

V3 Montag entlasten. Der Montag ist im Modell 4,5 Minuten langsamer als der Dienstag. 22,5 % aller Lieferungen kommen am Montag. Vorschlag: Mit den Lieferanten Wunschliefertage abstimmen, damit sich die Lieferungen besser auf Dienstag bis Donnerstag verteilen.

Kosten-Nutzen. Für die Bewertung gelten die Annahmen aus Kapitel 2.4: 700 Lieferungen pro Monat und 19,00 € Stundensatz. Der Umsetzungsaufwand wurde geschätzt (V1: 6 h, V2: 4 h, V3:

3 h, zusammen 13 h) und muss mit dem Fachbereich abgestimmt werden. Als Nutzen gilt der Effekt aus dem Regressionsmodell (Kapitel 5.2). Es wurden zwei Fälle gerechnet: im Fall „Potenzial“ beseitigt die Maßnahme den ganzen Effekt, im vorsichtigen Fall die Hälfte. Dabei wurde angenommen, dass eine Minute kürzere Durchlaufzeit eine Minute Arbeitszeit spart. Das ist eine Obergrenze, weil in der Durchlaufzeit auch Wartezeit steckt.

Maßnahme	Betroffene Lieferungen	Wirkung (Min.)	Umsetzung (€)	Einsparung (€/Monat) vorsichtig bis Potenzial	Amortisation (Monate) vorsichtig bis Potenzial
V1 Voranmeldung mit Zeitfenster	329 (16,3 %)	7,3	114	132 bis 265	0,9 bis 0,4
V2 Ursachen bei LF03 und LF07 klären	459 (22,7 %)	7,3 und 9,2	76	201 bis 402	0,4 bis 0,2
V3 Montag entlasten	454 (22,5 %)	4,5	57	112 bis 223	0,5 bis 0,3
Summe			**247**	**445 bis 891**	**0,6 bis 0,3**

Tabelle 20: Verbesserungsvorschläge mit Kosten-Nutzen

Alle drei Maßnahmen zusammen sparen im Mittel 2,0 bis 4,0 Minuten pro Lieferung, das sind 445 bis 891 € pro Monat. Die Maßnahmen amortisieren sich in 0,6 bzw. 0,3 Monaten. Rechnet man die Projektkosten (1.605 €) dazu, sind es 1.852 €. Diese sind nach 4,2 bzw. 2,1 Monaten gedeckt. Die Reihenfolge nach Amortisation: V2, V3, V1. In Kapitel 2.4 wurden 5 und 10 Minuten Einsparung geplant. Die Daten zeigen weniger. Die Wirtschaftlichkeit bleibt aber in beiden Fällen innerhalb eines halben Jahres gegeben (Vergleich in Kapitel 7.3). Die Wirkung der Maßnahmen ist nicht getestet. Ein statistischer Zusammenhang ist kein Beweis für eine Ursache. Darum wird ein Test von V1 über drei Monate mit anschließender neuer Auswertung empfohlen (Ausblick).

5.5 Soll-Ist-Abgleich während der Umsetzung

Dieses Kapitel zeigt den Zwischenstand nach Phase 6 (Optimierung). Verglichen werden die geplante und die tatsächliche Zeit (Tabelle 21) und die geplanten und tatsächlichen Inhalte (Tabelle 22).

Zeit. Für die Phasen 1 bis 6 waren 31 Stunden geplant. Gebraucht wurden ebenfalls 31 Stunden. Zwischen den Phasen gab es kleine Unterschiede:

- Arbeitspaket 3.2 (Daten bereinigen) brauchte 0,5 Stunden weniger. Die Prüfregeln aus Arbeitspaket 3.1 konnten ohne Änderung weiterverwendet werden.
- Arbeitspaket 4.2 (Zusammenhänge untersuchen) brauchte 1,0 Stunde mehr. Die Positionen wurden zusätzlich geprüft, und es wurde ein zweites Modell gerechnet (Kapitel 5.2).
- Arbeitspaket 5.2 (Ergebnisse interpretieren) brauchte 0,5 Stunden weniger, weil die Tabellen aus 4.1 und 4.2 schon vorlagen.

Phase	Soll (h)	Ist (h)	Unterschied (h)
1 Analyse	4	4	0
2 Planung	4	4	0
3 Datenvorbereitung	7	6,5	−0,5
4 Datenanalyse	8	9	+1,0
5 Auswertung	4	3,5	−0,5
6 Optimierung	4	4	0
Summe	**31**	**31**	**0**

Tabelle 21: Soll-Ist-Vergleich der Zeit (Phase 1 bis 6)

Weil die Gesamtzeit gleichblieb, blieben auch die Personalkosten gleich (Kapitel 2.4). Alle Meilensteine bis M4 wurden zum geplanten Datum erreicht. Für die Phasen 7 bis 9 bleiben 9 Stunden. Das entspricht der Planung.

Inhalt. Bei drei Punkten wich das Ergebnis von der Planung ab (Tabelle 22).

Punkt	Soll (Planung)	Ist (Ergebnis)	Grund
Merkmale im Regressionsmodell	ohne Positionen (Kapitel 4.2)	mit Positionen	VIF unter 3 und R^2 stieg von 0,532 auf 0,581 (Kapitel 5.2)
Einsparung je Lieferung	5 bis 10 Minuten (Kapitel 2.4)	2,0 bis 4,0 Minuten	Berechnung aus den Daten (Kapitel 5.4)
Amortisation (nur Projektkosten)	1,4 bis 0,7 Monate (Kapitel 2.4)	3,6 bis 1,8 Monate	Kleinere Einsparung (Kapitel 5.4)

Tabelle 22: Soll-Ist-Vergleich der Inhalte

Der Nutzen ist kleiner als in Kapitel 2.4 angenommen. Die Planwerte waren Schätzungen ohne Daten. Das Projekt lohnt sich trotzdem, denn die Kosten sind in weniger als einem halben Jahr gedeckt (Kapitel 5.4). Der endgültige Vergleich folgt in Kapitel 7.3.

6 Qualitätssicherung und Abnahme

6.1 Testkonzept

Bei der Datenanalyse werden Daten, Berechnungen und Ergebnisse geprüft. Die Tests laufen am Ende des Notebooks automatisch (Abschnitt 7 im Notebook). Jeder Test liefert entweder bestanden (True) oder nicht bestanden (False).

Es gibt fünf Testarten:

- **Datentests (T2-T5)**: Prüfen Vollständigkeit und Plausibilität der bereinigten Daten.
- **Rechentests (T6-T8)**: Prüfen die Berechnungen. Wichtige Werte werden zusätzlich mit NumPy berechnet.
- **Modelltest (T9)**: Prüft, ob das Regressionsmodell auch mit neuen Daten funktioniert.
- **Schutz- und Wiederholbarkeitstests (T1, T10, T11)**: Prüfen den Schutz der Originaldaten, das Fehlen personenbezogener Daten sowie gleichbleibende Ergebnisse. T11 prüft das Zusammenspiel aller Schritte.
- **Abnahmetest (Kapitel 6.3)**: Prüft, ob die vier Anforderungen aus Kapitel 2.2 erfüllt sind.

Erfolgskriterium: Alle Tests sind bestanden.

6.2 Testergebnisse (Testmatrix)

Tabelle 23 vergleicht für jeden Test die Erwartung (Soll) mit dem Ergebnis (Ist).

Nr.	Testfall	Soll	Ist	Status
T1	Rohdatei bleibt unverändert (Fingerabdruck MD5)	Fingerabdruck vorher = nachher	gleich	bestanden
T2	Zeilenbilanz	2.109 = 2.020 + 89	2.109 = 2.020 + 89	bestanden
T3	Keine fehlenden Werte, keine doppelten Lieferungen	0 und 0	0 und 0	bestanden
T4	Palettenzahl 1 bis 33, fünf Warenarten	alle Werte im Bereich, 5 Arten	erfüllt, 5 Arten	bestanden
T5	Alle Schrittzeiten größer 0, Gesamtzeit 30 bis 150 Min.	erfüllt	kleinste 33,7, größte 148,1 Min.	bestanden
T6	Summe der vier Schritte = Gesamtzeit	gleich	gleich (Abweichung unter 0,000001 Min.)	bestanden
T7	Kennzahlen mit NumPy neu gerechnet	gleiche Werte	gleich (75,3 / 74,3 / 97,8 Min.)	bestanden

Nr.	Testfall	Soll	Ist	Status
T8	Regression mit NumPy neu gerechnet	gleiche Koeffizienten	gleich	bestanden
T9	Modell B mit neuen Daten (20 % Testdaten)	R^2 über 0,5	R^2 = 0,585	bestanden
T10	Keine Spalten mit Personenbezug	nur erwartete Spalten	erfüllt	bestanden
T11	Notebook zweimal von oben nach unten ausführen	alle 12 Ergebnisdateien gleich	gleich (Fingerabdruck)	bestanden

Tabelle 23: Testmatrix

Ergebnis. Alle 11 Tests wurden bestanden. In den Daten und in den Rechnungen wurde kein Fehler gefunden. Bei der Prüfung der Dokumentation fielen drei Fehler auf, die korrigiert wurden: falsche Tabellenverweise, eine ungenaue Aussage zur Kühlware (Kapitel 5.3) und fehlende Ergebnisse der statistischen Tests (Kapitel 5.2). T1 bis T10 laufen im Notebook, T11 wurde mit einem zweiten Lauf geprüft.

6.3 Übergabe und Abnahme

Übergabe. Am 22.04.2027 wird das Ergebnispaket an den Auftraggeber übergeben (Meilenstein M5, Kapitel 3.4). Es enthält das Notebook, die bereinigten Daten, die Ergebnistabellen und Diagramme, die Verbesserungsvorschläge sowie die Projekt- und die Kundendokumentation (Kapitel 14). In der Ergebnisbesprechung (0,5 Stunden) erklärt der Projektbearbeiter die wichtigsten Ergebnisse und beantwortet Fragen. Weil die Kundendokumentation die Bedienung erklärt, ist keine zusätzliche Schulung nötig.

Abnahme. Der Auftraggeber prüft die vier Kernanforderungen aus Kapitel 2.2. Tabelle 24 zeigt das Ergebnis. Die Abnahme ist in diesem Übungsprojekt fiktiv.

Kernanforderung	Nachweis	Ergebnis
Die Analyse ist nachvollziehbar und wiederholbar.	Test T11; Anleitung in Kapitel 14.2	erfüllt
Die Ergebnisse sind für den Fachbereich verständlich.	Einfache Diagramme (Abbildung 3, Abbildung 4); Nutzen in Euro (Tabelle 20)	erfüllt
Die Originaldaten werden nicht verändert.	Test T1	erfüllt
Es werden keine personenbezogenen Daten ausgewertet.	Test T10; Schutzbedarfsanalyse (Kapitel 2.5)	erfüllt

Tabelle 24: Abnahmekriterien

7 Projektergebnisse

7.1 Darstellung des Endergebnisses

Am Ende des Projekts liegen diese Ergebnisse vor:

- **Notebook** analyse_wareneingang.ipynb: Es prüft die Daten, berechnet die Kennzahlen, führt die Statistik aus und zeichnet die Diagramme (Kapitel 5).
- **Daten**: 2.020 bereinigte Lieferungen und eine Fehlerliste mit 89 Zeilen und dem Grund.
- **Ergebnisdateien**: 12 Dateien im Ordner 03_Ergebnisse (10 CSV-Dateien und 2 Diagramme).
- **Verbesserungsvorschläge**: drei Maßnahmen mit Kosten, Nutzen und Amortisation (Kapitel 5.4).
- **Dokumentation**: Projektdokumentation und Kundendokumentation (Kapitel 14).

Wichtigste Aussagen. Eine Lieferung braucht im Mittel 75,3 Minuten (Median 74,3 Minuten). 90 % sind nach 97,8 Minuten fertig. Annahme und Kontrolle machen zusammen 61 % der Zeit aus. Die Zeit hängt vor allem von der Menge (Paletten und Positionen), der Warenart, dem Lieferanten, der Voranmeldung und dem Wochentag ab. Das Modell erklärt 58,1 % der Unterschiede. Drei Maßnahmen können 2,0 bis 4,0 Minuten pro Lieferung sparen.

7.2 Abgleich mit den Projektzielen

Tabelle 25 vergleicht die Ziele aus Kapitel 3.1 mit dem Ergebnis. Das Hauptziel und alle Teilziele wurden erreicht.

Art	Ziel	Ergebnis	Status
fachlich	Daten prüfen und bereinigen	89 fehlerhafte Zeilen entfernt, 42 Schreibweisen korrigiert (Kapitel 5.1)	erreicht
fachlich	Durchlaufzeiten und Kennzahlen berechnen	Mittelwert, Median und P90 für die Gesamtzeit und die vier Schritte (Tabelle 16)	erreicht
fachlich	Zusammenhänge untersuchen	Spearman, Kruskal-Wallis und Regression mit $R^2 = 0{,}581$ (Tabelle 19)	erreicht
fachlich	Verständliche Diagramme	Vier Diagramme (Abbildung 3, Abbildung 4)	erreicht
fachlich	Verbesserungen bewerten	Drei Vorschläge mit Kosten, Nutzen und Amortisation (Tabelle 20)	erreicht
organisatorisch	Entscheidungsgrundlage und Kundendokumentation	Kapitel 5.4 und Kapitel 14	erreicht
organisatorisch	Originaldaten unverändert, keine produktiven Systeme	Test T1 (Kapitel 6.2)	erreicht
organisatorisch	Quellen und KI-Hilfsmittel angeben	Kapitel 9 und 10	erreicht
zeitlich	40 Stunden, davon höchstens 6 für die Dokumentation	40 Stunden, davon 6 (Tabelle 26)	erreicht
zeitlich	Durchführung vom 12.04. bis 23.04.2027	Zeitraum eingehalten	erreicht

Tabelle 25: Abgleich mit den Projektzielen

7.3 Bewertung des Nutzens für den Betrieb

Nutzen in Euro. Die drei Maßnahmen sparen im Mittel 2,0 bis 4,0 Minuten pro Lieferung (vorsichtiger Fall bis Potenzial, Kapitel 5.4). Das sind 445 bis 891 € pro Monat. In Kapitel 2.4 waren 5 bis 10 Minuten geplant. Der Plan war zu optimistisch, weil er auf Schätzungen ohne Daten beruhte.

Amortisation. Die Projektkosten (1.605 €) sind nach 3,6 bis 1,8 Monaten gedeckt. Mit den Kosten für die Umsetzung (247 €, zusammen 1.852 €) sind es 4,2 bis 2,1 Monate. In beiden Fällen lohnt sich das Projekt innerhalb eines halben Jahres. Nach einem Jahr bleibt ein Gewinn von etwa 3.500 € (vorsichtiger Fall) bis 8.800 € (Potenzial).

Nutzen ohne Euro. Der Wareneingang weiß jetzt, wo die Zeit vergeht. Entscheidungen stützen sich auf Daten und nicht auf Vermutungen. Die Analyse kann mit neuen Daten in wenigen Minuten wiederholt werden (Kapitel 14).

Grenzen. Die Daten sind erfunden (synthetisch). Die Aussagen gelten deshalb für dieses Übungsprojekt und nicht für ein echtes Lager. Die Wirkung der Maßnahmen ist nicht getestet. Das Modell erklärt 58,1 % der Unterschiede, der Rest ist unbekannt.

8 Fazit und Ausblick

8.1 Zusammenfassung

Im Projekt wurden die Durchlaufzeiten im Wareneingang der MainLogistik GmbH anhand von rund 2.100 Prozessdaten des ersten Quartals 2027 analysiert. Nach einer Bereinigung (89 fehlerhafte Zeilen, 4,2 %) blieben 2.020 auswertbare Lieferungen. Die Analyse zeigte: Eine typische Lieferung braucht 74,3 Minuten (Median); Annahme und Kontrolle verursachen zusammen 61 % der Zeit. Als Ursachen für lange Zeiten wurden mit statistischen Verfahren belegt: fehlende Voranmeldung, die Lieferanten LF03 und LF07, der Montag und die Menge (Paletten und Positionen). Daraus wurden drei Verbesserungsvorschläge (V1 bis V3) entwickelt und wirtschaftlich bewertet. Zusammen sparen sie voraussichtlich 445 bis 891 € pro Monat; die Gesamtkosten (Projekt + Umsetzung) sind in 4,2 bis 2,1 Monaten wieder eingespart. Alle Ziele wurden erreicht, der Zeitrahmen von 40 Stunden wurde eingehalten.

8.2 Soll-Ist-Vergleich (Zeit, Kosten, Ziele)

Zeit. Tabelle 26 zeigt die Phasen 7 bis 9. Sie ergänzt den Vergleich der Phasen 1 bis 6 aus Kapitel 5.5 (Tabelle 21). Alle Phasen brauchten genau die geplante Zeit.

Phase	Soll (h)	Ist (h)	Unterschied (h)
7 Qualitätssicherung	2	2	0
8 Projektabschluss	1	1	0
9 Projektdokumentation	6	6	0
Summe Phase 7 bis 9	**9**	**9**	**0**
Gesamt (Phase 1 bis 9)	**40**	**40**	**0**

Tabelle 26: Soll-Ist-Vergleich der Zeit (Phase 7 bis 9)

Kosten und Nutzen. Weil die Zeit gleichblieb, blieben auch die Projektkosten gleich (Kapitel 2.4). Der Nutzen ist kleiner als geplant. Tabelle 27 zeigt den Vergleich.

Größe	Soll (Plan, Kapitel 2.4)	Ist (Ergebnis)
Projektkosten	1.605 €	1.605 €
Einsparung je Lieferung	5 bis 10 Minuten	2,0 bis 4,0 Minuten
Einsparung pro Monat	1.108 bis 2.217 €	445 bis 891 €
Amortisation (nur Projektkosten)	1,4 bis 0,7 Monate	3,6 bis 1,8 Monate
Amortisation mit Umsetzung (247 €)	nicht geplant	4,2 bis 2,1 Monate

Tabelle 27: Soll-Ist-Vergleich der Kosten und des Nutzens

Ziele. Alle Ziele wurden erreicht (Tabelle 25). Die Abweichungen bei den Inhalten (zweites Regressionsmodell, kleinerer Nutzen) stehen in Tabelle 22.

8.3 Reflexion und Ausblick

Reflexion. Das Wasserfallmodell hat sich für dieses Ein-Personen-Projekt bewährt: Die feste Reihenfolge (erst Daten prüfen, dann analysieren, dann bewerten) hat verhindert, dass auf schlechten Daten aufgebaut wurde. Am schwierigsten war die Entscheidung zum Regressionsmodell: Die Positionen sollten laut Plan nicht ins Modell aufgenommen werden (Multikollinearität mit den Paletten). Die Prüfung mit dem VIF zeigte aber, dass beide Merkmale zusammen im Modell bleiben dürfen und das Modell besser wird (R^2 0,532 → 0,581). Diese Prüfung kostete eine Stunde mehr als geplant, war aber sinnvoll. Für die Zukunft hat der Projektbearbeiter gelernt: Erstens: Daten zuerst prüfen. Fast jede 24. Zeile (4,2 %) war fehlerhaft. Zweitens: Ein Ergebnis braucht eine zweite Rechnung zur Kontrolle. Drittens: Ein Zeitplan mit täglichem Soll-Ist-Vergleich hilft, die 40 Stunden einzuhalten.

Ausblick. Diese Schritte sind danach sinnvoll:

- **Test von V1:** Alle Lieferanten melden Lieferungen mit Zeitfenster an. Nach drei Monaten wird die Auswertung mit neuen Daten wiederholt.
- **Regelmäßige Wiederholung:** Das Notebook kann mit jeder neuen CSV-Datei erneut laufen. Eine Auswertung je Quartal (und – wie vom Auftraggeber gewünscht – je Monat) ist mit wenigen Anpassungen möglich.
- **Mehr Detailtiefe:** Bisher enthält die Durchlaufzeit Warte- und Bearbeitungszeit zusammen. Eine zusätzliche Erfassung dieser beiden Zeiten würde zeigen, wo mehr Personal (Bearbeitung) und wo bessere Organisation (Warten) hilft.
- **Dashboard:** Die Kennzahlen (Median, P90, Anteile der Schritte) könnten als Dashboard für die Leitung aufbereitet werden, damit Veränderungen sofort sichtbar werden.

9 Verwendete KI-Hilfsmittel

KI-Tool (Name, Anbieter, URL, letzter Aufruf)	Verwendungszweck bzw. Einsatzszenario	Stellenangabe in der Arbeit (Kapitel- und Seitenangabe)	Ergänzende Hinweise
Claude, Anthropic, https://claude.ai, letzter Aufruf: 22.10.2026	Erstellung eines Python-Skripts für synthetische Prozessdaten	Kapitel 4.1, Seite 10	Skript vom Prüfling ausgeführt, Ergebnis in Excel geprüft
Claude, Anthropic, https://claude.ai, letzter Aufruf: 22.10.2026	Hilfe beim Python-Code des Notebooks (Statistik, Diagramme, Tests, Hashwert der Rohdatei)	Kapitel 5.2 bis 5.4 und 6.2.	Code vom Prüfling gelesen und getestet (Tests T1 bis T11, Kapitel 6.2)
Claude, Anthropic, https://claude.ai, letzter Aufruf: 22.10.2026	Überprüfung der deutschen Grammatik, Korrektur der Formulierungen	Das ganze Dokument	Texte vom Prüfling gelesen, geprüft und angepasst
Claude, Anthropic, https://claude.ai, letzter Aufruf: 22.10.2026	Formatierung der Dokumente nach dem Merkblatt der IHK	Das ganze Dokument	Texte vom Prüfling gelesen, geprüft und angepasst

Tabelle 28: Verwendete KI-Hilfsmittel

10 Quellenverzeichnis

- Europäische Union: Verordnung (EU) 2016/679 (DSGVO), Art. 4 und 5. https://eur-lex.europa.eu/eli/reg/2016/679/oj, letzter Aufruf: 14.10.2026
- BSI: BSI-Standard 200-2, IT-Grundschutz-Methodik. www.bsi.bund.de, letzter Aufruf: 14.10.2026
- SciPy: scipy.stats.spearmanr. https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.spearmanr.html, letzter Aufruf: 15.10.2026
- SciPy: scipy.stats.kruskal. https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.kruskal.html, letzter Aufruf: 15.10.2026
- Statsmodels: Linear Regression. https://www.statsmodels.org/stable/regression.html, letzter Aufruf: 15.10.2026

11 Glossar

Das Glossar erklärt Begriffe, die im Text und in der Kundendokumentation vorkommen.

Begriff	Erklärung
Amortisation	Zeit, nach der die Einsparung die Kosten deckt (Kapitel 2.4).
Ausreißer	Ein Wert, der weit weg von allen anderen liegt. Hier: Gesamtzeit über 8 Stunden (Kapitel 5.1).
Avisierung (Voranmeldung)	Der Lieferant meldet die Lieferung vorher an. In den Daten: Spalte „avisiert“ (ja oder nein).

Begriff	Erklärung
Bereinigung	Fehlerhafte Zeilen entfernen und Schreibweisen vereinheitlichen.
Bestimmtheitsmaß (R^2)	Zahl zwischen 0 und 1. Sie zeigt, wie viel der Unterschiede in der Durchlaufzeit das Modell erklärt. 0,581 heißt: 58,1 %.
Dummy-Variable	Eine Kategorie (zum Beispiel Gefahrgut) als 0/1-Spalte im Modell. 1 bedeutet: trifft zu.
Durchlaufzeit	Zeit von der Ankunft der Ware bis „bereit zur Einlagerung“, in Minuten.
Kruskal-Wallis-Test	Test, ob sich mehrere Gruppen (zum Beispiel Lieferanten) wirklich unterscheiden oder nur zufällig.
Median	Mittlerer Wert: Die Hälfte der Werte ist kleiner, die Hälfte ist größer.
Multikollinearität	Zwei Merkmale hängen so eng zusammen, dass das Modell ihre Wirkung nicht mehr trennen kann. Prüfung mit dem VIF-Wert.
Notebook (Jupyter)	Dokument, in dem Text, Programmcode und Ergebnisse zusammenstehen.
P90 (90-%-Perzentil)	90 % der Werte sind kleiner oder gleich diesem Wert. Er zeigt die langsamen Lieferungen.
p-Wert	Zeigt, wie wahrscheinlich ein Ergebnis nur Zufall ist. Unter 0,05 gilt es als sicher (signifikant).
Regression	Modell, das die Wirkung mehrerer Merkmale auf eine Zielgröße berechnet (hier: die Durchlaufzeit).
Schiefe	Zeigt, ob die Verteilung nach rechts (zu langen Zeiten) ausläuft. Positiv bedeutet rechtsschief.
Spearman-Korrelation	Maß von −1 bis +1: Gehören höhere Werte eines Merkmals zu höheren Werten eines anderen?
Synthetische Daten	Erfundene Daten, die echten Daten nachgebaut sind. Sie enthalten keine Personendaten.
Zeitstempel	Datum und Uhrzeit einer Buchung.

Tabelle 29: Glossar

12 Abkürzungsverzeichnis

Abkürzung	Bedeutung
BSI	Bundesamt für Sicherheit in der Informationstechnik
CSV	Comma-Separated Values (Dateiformat für Tabellendaten)
DSGVO	Datenschutz-Grundverordnung
FAQ	Frequently Asked Questions (häufige Fragen)
GmbH	Gesellschaft mit beschränkter Haftung
IHK	Industrie- und Handelskammer
IT	Informationstechnik
KI	Künstliche Intelligenz
KPI	Key Performance Indicator (Leistungskennzahl)
LVS	Lagerverwaltungssystem
MD5	Message-Digest Algorithm 5 (Fingerabdruck einer Datei)
OLS	Ordinary Least Squares (Methode der kleinsten Quadrate, Art der Regression)
PNG	Portable Network Graphics (Bildformat)
VIF	Variance Inflation Factor (Maß für die Überschneidung von Merkmalen)

Tabelle 30: Abkürzungsverzeichnis

13 Anlagen

13.1 Anlage 1: Detaillierte Zeitplanung

Nr.	Arbeitspaket	Std.	Datum
1	**Analyse**	**4**	**Mo 12.04.**
1.1	Ist-Zustand des Wareneingangs analysieren	2	12.04.
1.2	Anforderungen an die Datenanalyse festlegen	1	12.04.
1.3	Wirtschaftlichkeit und Datenschutz betrachten	1	12.04.
2	**Planung**	**4**	**Di 13.04.**
2.1	Vorgehensmodell und Datenanforderungen planen	2	13.04.
2.2	Analysemethoden und Kennzahlen auswählen	2	13.04.
3	**Datenvorbereitung**	**7**	**Mi 14.04. – Do 15.04.**
3.1	Daten übernehmen und Datenqualität prüfen	3	14.04.
3.2	Daten bereinigen und aufbereiten	4	14.04. (1 h), 15.04. (3 h)
4	**Datenanalyse**	**8**	**Do 15.04 – Mo 19.04**
4.1	Durchlaufzeiten und Kennzahlen berechnen	4	15.04. (1 h), 16.04. (3 h)
4.2	Zusammenhänge untersuchen (Korrelation, Regression)	4	16.04. (1 h), 19.04. (3 h)
5	**Auswertung**	**4**	**Mo 19.04. – Di 20.04.**
5.1	Ergebnisse visualisieren	2	19.04. (1 h), 20.04. (1 h)
5.2	Ergebnisse interpretieren	2	20.04.
6	**Optimierung**	**4**	**Di 20.04 – Mi 21.04.**
6.1	Verbesserungsmöglichkeiten entwickeln	2	20.04. (1 h), 21.04. (1 h)
6.2	Verbesserungen bewerten (Kosten-Nutzen, Amortisation)	2	21.04.
7	**Qualitätssicherung**	**2**	**Mi 21.04 – Do 22.04.**
7.1	Validierung der Ergebnisse	1	21.04.
7.2	Ergebnisse mit den Anforderungen vergleichen	1	22.04.
8	**Projektabschluss**	**1**	**Do 22.04**
8.1	Ergebnisse zusammenfassen und übergeben	1	22.04.
9	**Projektdokumentation**	**6**	**Do 22.04. – Fr 23.04.**
9.1	Projektdokumentation erstellen	4	22.04. (2 h), 23.04. (2 h)
9.2	Kundendokumentation erstellen	1	23.04.
9.3	Projektdokumentation abschließend prüfen	1	23.04.
	Gesamt	**40**	

Tabelle 31: Detaillierte Zeitplanung

14 Kundendokumentation

Kundendokumentation zur Analyse der Durchlaufzeiten im Wareneingang

Anwendung	Jupyter Notebook „analyse_wareneingang.ipynb“ der MainLogistik GmbH
Zielgruppe	Leitung Wareneingang und Mitarbeitende im Fachbereich
Version und Datum	Version 1.0, 23.04.2027
Ersteller	Vladimir Larionov (Projektbearbeiter)

Inhalt dieser Kundendokumentation

14.1 Einführung (Zweck und Zielgruppe) 1
14.2 Bedienungsanleitung / Hinweise zur Auswertung 1
14.3 Technische Hinweise (Systemvoraussetzungen, Installation) 2
14.4 Anhang (Kurzanleitung, FAQ) 3

14.1 Einführung (Zweck und Zielgruppe)

Zweck. Diese Anleitung erklärt, wie man die Ergebnisse der Analyse liest und wie man die Analyse mit neuen Daten selbst wiederholt. Programmierkenntnisse sind dafür nicht nötig.

Zielgruppe. Die Anleitung ist für die Leitung des Wareneingangs und für Mitarbeitende im Fachbereich. Sie kennen den Wareneingang sehr gut. Vorwissen in Datenanalyse brauchen sie nicht. Fachbegriffe stehen im Glossar (Kapitel 11).

Was ist die Anwendung. Die Anwendung ist ein Jupyter Notebook. Ein Notebook ist ein Dokument, in dem Text, Rechenschritte und Ergebnisse zusammenstehen. Es liest die Prozessdaten des Wareneingangs ein, prüft sie, rechnet die Durchlaufzeiten aus und erstellt Tabellen und Diagramme. Die Rohdaten werden dabei nie verändert.

14.2 Bedienungsanleitung / Hinweise zur Auswertung

A. Ergebnisse lesen (ohne Programm). Alle Ergebnisse liegen im Ordner 03_Ergebnisse. Die CSV-Dateien öffnen Sie mit Excel (Trennzeichen: Semikolon). Die Diagramme öffnen Sie mit jedem Bildprogramm. Tabelle 32 zeigt, welche Datei welche Frage beantwortet.

Datei	Inhalt	Frage, die sie beantwortet
kennzahlen_gesamt.csv	Mittelwert, Median, P90, Minimum, Maximum	Wie lange dauert eine Lieferung?
kennzahlen_schritte.csv	Zeit und Anteil der vier Schritte	Wo vergeht die Zeit?
median_je_gruppe.csv	Median je Lieferant, Warenart, Wochentag, Voranmeldung	Welche Gruppe ist langsam?
regression_koeffizienten.csv	Wirkung jedes Merkmals in Minuten	Was verlängert die Zeit wirklich?
verbesserungen.csv	Maßnahmen mit Kosten, Nutzen, Amortisation	Was lohnt sich?
abb3_...png, abb4_...png	Diagramme	Überblick auf einen Blick
datenfehler_liste.csv	Entfernte Zeilen mit Grund	Welche Daten waren fehlerhaft?
wareneingang_bereinigt.csv	Saubere Daten mit neuen Spalten	Grundlage für eigene Auswertungen

Tabelle 32: Ergebnisdateien und ihre Bedeutung

So lesen Sie die wichtigsten Zahlen:

- **Median**: Die Hälfte der Lieferungen ist schneller, die Hälfte ist langsamer. Er zeigt die ttypische Lieferung.
- **P90**: 90 von 100 Lieferungen sind nach dieser Zeit fertig. Er zeigt die langsamen Lieferungen.

- **Wirkung in Minuten (Regression)**: die Zusatzzeit im Vergleich zur Vergleichsgruppe, wenn alle anderen Merkmale gleich sind. Ein p-Wert unter 0,05 bedeutet: Der Einfluss ist sicher und nicht Zufall.
- **Beispiel**: In der Datei regression_koeffizienten.csv steht bei „avisiert_nein“ der Wert 7,34. Das heißt: Lieferungen ohne Voranmeldung dauern bei sonst gleichen Merkmalen 7,3 Minuten länger.

B. Analyse mit neuen Daten wiederholen. Gehen Sie in dieser Reihenfolge vor:

1. Kopieren Sie den Projektordner mit den Unterordnern 01 bis 04 auf Ihren Rechner.

2. Legen Sie die neuen Daten als CSV-Datei mit dem Namen wareneingang_roh.csv in den Ordner 01_Rohdaten. Sichern Sie die alte Datei vorher. Die Spalten müssen heißen wie in Tabelle 11. Das Trennzeichen ist das Semikolon.

3. Starten Sie Jupyter Notebook (siehe Kapitel 14.3). Öffnen Sie die Datei analyse_wareneingang.ipynb im Ordner 02_Notebook.

4. Wählen Sie im Menü „Kernel“ den Punkt „Restart Kernel and Run All Cells“. Das Notebook läuft jetzt von oben nach unten. Das dauert nur wenige Sekunden.

5. Ganz unten stehen die Tests. Alle zehn Zeilen müssen mit „True“ beginnen. Bei „False“ lesen Sie die Antworten im Anhang (Kapitel 14.4).

6. Die neuen Ergebnisse stehen im Ordner 03_Ergebnisse. Achtung: Alte Ergebnisse werden überschrieben. Sichern Sie diese vorher.

Eigene Werte ändern. Den Stundensatz (STUNDENSATZ = 19.0) und die Zahl der Lieferungen pro Monat (700) finden Sie im Abschnitt „6. Verbesserungsvorschläge“ des Notebooks. Die Vorschläge in diesem Abschnitt sind auf die Lieferanten LF03 und LF07 und auf den Montag zugeschnitten. Bei neuen Daten müssen sie angepasst werden.

14.3 Technische Hinweise (Systemvoraussetzungen, Installation)

Systemvoraussetzungen. Sie brauchen einen normalen Büro-PC (Windows, macOS oder Linux) mit Python und den Paketen aus Tabelle 33. Die Analyse wurde mit diesen Versionen getestet.

Paket	Aufgabe	Getestete Version
Python	Programmiersprache	3.14
pandas	Daten einlesen, bereinigen, berechnen	3.0.2
NumPy	Rechnen mit Zahlen	2.4.4
SciPy	Statistische Tests	1.17.1
statsmodels	Regression	0.15.0
Matplotlib	Diagramme	3.10.8
Jupyter Notebook	Notebook ausführen	aktuelle Version

Tabelle 33: Benötigte Pakete und getestete Versionen

Installation. Geben Sie in der Eingabeaufforderung (Windows) oder im Terminal (macOS, Linux) diesen Befehl ein:

```
pip install pandas numpy scipy statsmodels matplotlib notebook
```

Start. Wechseln Sie in den Ordner 02_Notebook und geben Sie diesen Befehl ein. Danach öffnet sich der Browser:

```
jupyter notebook
```

Ordner. 01_Rohdaten enthält die Rohdatei wareneingang_roh.csv (nur lesen). 02_Notebook enthält das Notebook. 03_Ergebnisse enthält alle Ergebnisdateien. 04_Dokumentation enthält die Dokumentation als PDF.

Datenschutz. Die Daten im Projekt sind erfunden. Bei echten Daten gilt: Keine personenbezogenen Angaben (zum Beispiel Namen von Fahrern) in die Datei aufnehmen und die Daten nur auf dem Firmenrechner speichern.

14.4 Anhang (Kurzanleitung, FAQ)

Kurzanleitung in fünf Schritten

1. Neue Datei wareneingang_roh.csv in den Ordner 01_Rohdaten legen.
2. Notebook analyse_wareneingang.ipynb öffnen.
3. Im Menü „Kernel“ den Punkt „Restart Kernel and Run All Cells“ wählen.
4. Ganz unten prüfen: Alle Tests zeigen „True“.
5. Ergebnisse im Ordner 03_Ergebnisse ansehen.

Häufige Fragen (FAQ)

Frage oder Meldung	Antwort
„FileNotFoundError“ oder „Datei nicht gefunden“	Die Datei heißt nicht wareneingang_roh.csv oder liegt nicht im Ordner 01_Rohdaten. Prüfen Sie Namen und Ordner. Das Notebook muss im Ordner 02_Notebook geöffnet sein.
Ein Test zeigt „False“	Die Tests T2 bis T5 prüfen feste Grenzen (1 bis 33 Paletten, 5 Warenarten, 30 bis 150 Minuten). Bei anderen Daten müssen diese Werte im Notebook angepasst werden. Die Datei datenfehler_liste.csv zeigt, welche Zeilen entfernt wurden.
„KeyError“ im Abschnitt Regression	Es gibt neue Lieferanten oder Warenarten. Die Regression nennt feste Vergleichsgruppen (LF01, Trockenware, Montag, avisiert „ja“). Passen Sie diese Zeile an oder fragen Sie den Projektbearbeiter.
Wo ändere ich den Stundensatz?	Im Abschnitt „6. Verbesserungsvorschläge“, Zeile STUNDENSATZ = 19.0.
Die Zahlen sind anders als in der Dokumentation.	Mit neuen Daten ändern sich die Ergebnisse. Mit den Originaldaten müssen sie gleich sein.
Excel zeigt alles in einer Spalte.	Wählen Sie in Excel „Daten, Aus Text/CSV“ und stellen Sie das Trennzeichen „Semikolon“ ein.

Tabelle 34: FAQ